SEMINAR · CS2308

BioRerank: Evaluating Document Reranking Models for Biomedical Information Retrieval

Nhóm 11
Nguyễn Hải Đăng– 26848027
Hoàng Đức Chung– 26848017

Phát biểu bài toán reranking

Ký hiệu

- Kho tài liệu D (TREC-COVID: |D| = 171.331), truy vấn q.
- Bộ truy xuất tầng một R (ở đây là BM25) trả về tập ứng viên $C_q = (d_1, \ldots, d_k)$, với **k = 100 ≪ |D|**.
- Nhãn liên quan $rel_q(d) \in \{0, 1, 2\}$ lấy từ qrels của benchmark; tài liệu chưa đánh giá (unjudged) tính là 0.

Định nghĩa

Reranker là hàm f nhận truy vấn và tập ứng viên, trả về một **hoán vị** của tập đó:

Đầu ra $\pi = f(q, C_q)$

Mục tiêu $f^* = \arg\max_f \mathbb{E}_q[\text{nDCG@10}(\pi, \text{rel}_q)]$

Ràng buộc then chốt: reranker chỉ đổi thứ tự, không thêm và không bớt tài liệu.
→ tồn tại **cận trên oracle** (slide 5).
→ recall của tầng một chặn trên chất lượng của tầng hai.

So sánh với truy xuất tầng một (first-stage retrieval)

	Tầng một (retrieval)	Tầng hai (reranking)
Phạm vi	Toàn bộ kho (10^5–10^6 tài liệu)	k ứng viên (thường 20–1.000)
Ràng buộc	Mã hóa tài liệu offline, tra cứu qua index	Mã hóa chung (truy vấn, tài liệu), chấp nhận chi phí cao
Mục tiêu	Độ phủ: Recall@k	Thứ hạng đầu danh sách: nDCG@10
Ví dụ	BM25, bi-encoder (DPR, MedCPT retriever)	cross-encoder, LLM, Jev

Vì chỉ xử lý 100 tài liệu, reranker dùng được phép tính đắt mà tầng một không kham nổi: **mã hóa chung truy vấn–tài liệu (joint encoding)**.

Nguồn: NLP_PROJECT_PLAN.md mục 5; Abdallah et al. 2025 (thiết lập BM25 top-100).

Cùng tập ứng viên, nDCG@10 dao động từ 3 đến 100

TOPIC 26 · TREC-COVID

“What are the initial symptoms of Covid-19?”

Cùng 100 tài liệu ứng viên (BM25 top-100) cho mọi mô hình.

3 / 100

nDCG@10 của một reranker
(tên mô hình: công bố sau)

100 / 100

nDCG@10 của một reranker
(tên mô hình: công bố sau)

Thách thức của bài toán xếp hạng

1. **Lệch từ vựng (vocabulary mismatch)**
“initial symptoms” và “first clinical manifestations”: cùng nghĩa, khác từ vựng.

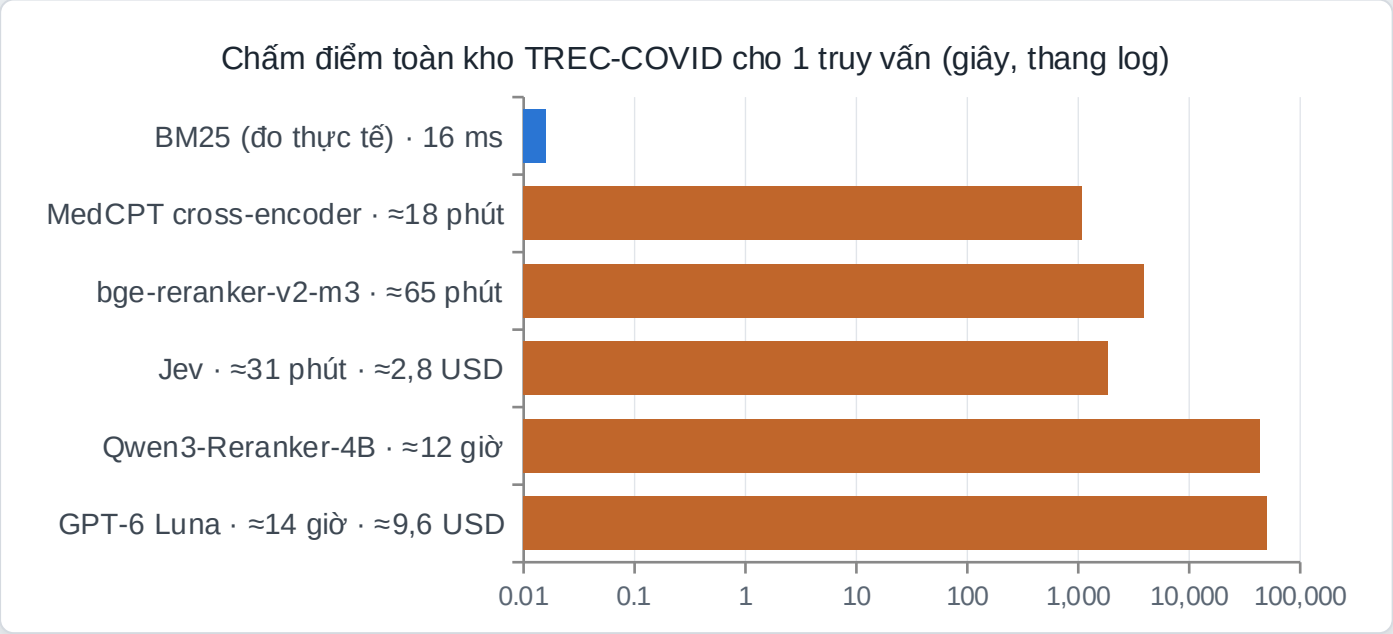
2. **Lệch phân phối truy vấn (distribution shift)**
Truy vấn là câu hỏi ngôn ngữ tự nhiên, trong khi nhiều mô hình quen với truy vấn từ khóa (“coronavirus early symptoms”).

3. **Từ ngoài từ vựng (OOV)**
“covid-19” không có trong các bộ từ vựng xây dựng trước 2019.

Tập ứng viên cố định → mọi chênh lệch đến từ **bước xếp hạng lại**: reranker.

Nguồn: results/e1/e1_per_query.json (topic 26); data/raw/trec_covid/topics-rnd5.xml.

Đánh đổi giữa chất lượng xếp hạng và chi phí suy luận



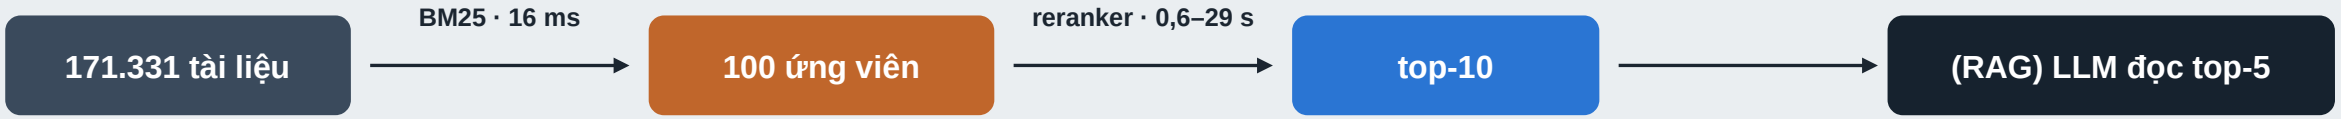
BM25: đo thực tế (trung vị, một luồng CPU). Còn lại: ngoại suy tuyến tính từ độ trễ rerank 100 tài liệu × 1.713.

Vì sao chênh nhau hơn 200 nghìn lần

BM25: chỉ mục ngược (inverted index)
Dựng trước (offline); lúc truy vấn chỉ duyệt posting list của các từ trong truy vấn.

Reranker neural: mã hóa chung (q, d)
Điểm phụ thuộc truy vấn nên không tính trước được; mỗi truy vấn cần một forward pass cho từng tài liệu.

Lời giải: kiến trúc xếp hạng nhiều tầng (multi-stage ranking)



Tầng một **rẻ**: tối ưu **recall** (không bỏ sót tài liệu liên quan).

Tầng hai **đắt**: tối ưu **precision ở top-k**. Tầng này chính là reranker.

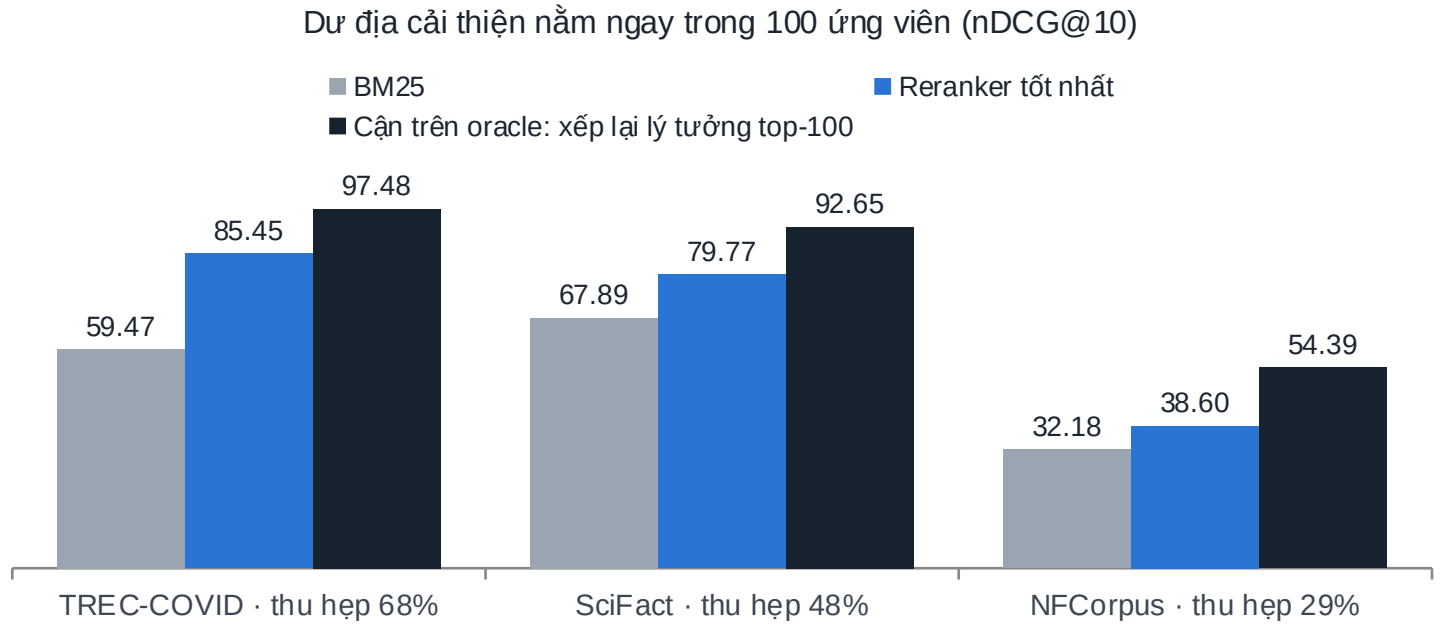
Nguồn: BM25 đo 11/11 bằng Pyserini, index beir-v1.0.0-trec-covid.flat, 50 truy vấn (phụ lục A12); độ trễ rerank 100 tài liệu và chi phí: report/tables/e4_cost.md (p50), ngoại suy × 1.713.

Tầng một tối ưu recall, nhưng RAG chỉ dùng vài tài liệu đầu

Khớp từ vựng, không khớp ngữ nghĩa (BM25).

Mã hóa tài liệu độc lập với truy vấn. Bi-encoder nén mỗi tài liệu thành một vector cố định, mất tương tác truy vấn–tài liệu ở mức token.

Mục tiêu tối ưu khác: tầng một tối ưu Recall@k, không tối ưu thứ hạng trong top-10.



Cận trên oracle = nDCG@10 khi xếp lại lý tưởng 100 ứng viên BM25 theo qrels (tài liệu chưa đánh giá tính 0). NFCorpus: 70/323 truy vấn không có tài liệu liên quan nào trong 100 ứng viên.

Ví dụ · topic 6: “rapid testing for Covid-19”

✗ BM25 hạng 1: “Coronavirus disease 2019 in children…”

✓ Sau rerank: “Types of Assays for SARS-CoV-2 Testing: A Review”

Trong RAG, LLM chỉ nhận top-k tài liệu. Ngữ cảnh dài tốn token; LLM khai thác thông tin ở giữa ngữ cảnh kém hơn ở hai đầu (Liu et al., Lost in the Middle, TACL 2024). → **Thứ hạng quan trọng**, không chỉ recall.

Nguồn: cận trên oracle tính 11/11 từ results/runs/<bộ>/test/bm25.trec và qrels (A11); reranker tốt nhất: report/tables/e1_main.md; topic 6: report/tables/error_cases.md; Liu et al. 2024.

Ba chiến lược suy luận: pointwise, pairwise, listwise

POINTWISE *chấm từng tài liệu*



HÀM CHẤM ĐIỂM
s(q, d) ∈ ℝ, rồi sắp xếp theo s

NGỮ CẢNH MỖI LƯỢT
1 tài liệu

SỐ LƯỢT GỌI (K = 100)
100 lượt, **song song hóa được**

VÍ DỤ
LambdaMART, BiLSTM, cross-encoder, MonoT5, Qwen3

HẠN CHẾ
Chấm độc lập: không mô hình hóa quan hệ giữa các ứng viên

PAIRWISE · SETWISE *so cặp / nhóm nhỏ*



HÀM CHẤM ĐIỂM
$P(d_i \succ d_j \mid q)$, rồi tổng hợp kết quả so cặp

NGỮ CẢNH MỖI LƯỢT
2 tài liệu (setwise: một nhóm nhỏ)

SỐ LƯỢT GỌI (K = 100)
4.950 cặp (all-pairs)

VÍ DỤ
PRP, Setwise

HẠN CHẾ
Độ phức tạp $O(k^2)$; có thể không bắc cầu ($A \succ B \succ C \succ A$)

LISTWISE *xếp cả danh sách*



HÀM CHẤM ĐIỂM
$f(q, d_1 \ldots d_k) \rightarrow$ hoán vị, hoặc $s(q, d_i \mid C_q)$

NGỮ CẢNH MỖI LƯỢT
Nhiều tài liệu trong một ngữ cảnh

SỐ LƯỢT GỌI (K = 100)
Cửa sổ trượt w = 20, bước s = 10: **9 lượt tuần tự**; Jev: **1 request** (chia lô khi quá dài)

VÍ DỤ
RankGPT, RankZephyr, ListT5, GPT-6 Luna, Jev

HẠN CHẾ
Giới hạn cửa sổ ngữ cảnh; **nhạy với thứ tự đầu vào**; đầu ra có thể thiếu hoặc trùng ID

Nguồn: Sun et al. 2023 (RankGPT, cửa sổ 20/10); Qin et al. 2023 (PRP); Zhuang et al. 2024 (Setwise); report/tables/e4_cost.md.

Huấn luyện: ba họ hàm mất mát learning-to-rank

Họ	Hàm mất mát	Ý nghĩa
Pointwise	$\mathcal{L} = -[y \log \sigma(s) + (1-y)\log(1-\sigma(s))]$	Phân loại nhị phân liên quan / không liên quan (monoBERT, MonoT5)
Pairwise (RankNet, 2005)	$\mathcal{L} = \log(1 + e^{-(s_i - s_j)}), \quad d_i \succ d_j$	Tài liệu liên quan phải có điểm cao hơn tài liệu không liên quan
Listwise (softmax, kiểu ListNet 2007)	$\mathcal{L} = -\log \frac{e^{s(d^+)}}{e^{s(d^+)} + \sum_{k=1}^{n} e^{s(d_k^-)}}$	Trong một nhóm ứng viên, positive phải có điểm cao nhất so với mọi negative
LambdaRank / LambdaMART	$\lambda_{ij} = \frac{\partial \mathcal{L}_{\text{RankNet}}}{\partial s_i} \cdot \lvert \Delta \text{nDCG}_{ij} \rvert$	Gradient nhân trọng số $\lvert\Delta$nDCG$\rvert$: lỗi ở top-10 bị phạt nặng, lỗi ở hạng 90 gần như không

Hàm mất mát huấn luyện ≠ chiến lược suy luận

LambdaMART huấn luyện bằng LambdaRank, BiLSTM-ESIM bằng softmax trên nhóm 1 positive + 7 negative, nhưng cả hai đều **suy luận pointwise**.

Không huấn luyện riêng cho rerank (zero-shot)

RankGPT (prompt), Jev (tiêu chí bằng ngôn ngữ tự nhiên).

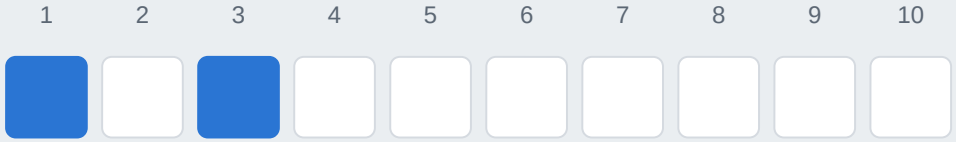
Nguồn: Burges et al. 2005 (RankNet); Cao et al. 2007 (ListNet); Burges 2010 (LambdaMART); src/rerank/lambdamart.py; src/kaggle_tasks/bilstm.py.

nDCG@10: độ đo có chiết khấu theo thứ hạng

$$\mathrm{DCG@10} = \sum_{i=1}^{10} \frac{\mathrm{rel}_i}{\log_2(i+1)} \qquad \mathrm{nDCG@10} = \frac{\mathrm{DCG@10}}{\mathrm{IDCG@10}}$$

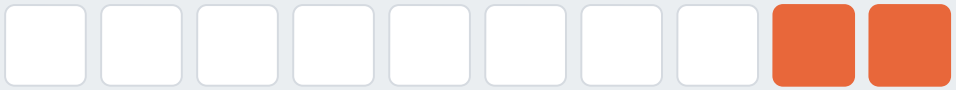
Gain tuyến tính (như BEIR, trec_eval); IDCG@10 là DCG@10 của thứ tự lý tưởng.

Ví dụ: truy vấn có 2 tài liệu liên quan (rel = 1)



nDCG ≈ **0,92**

hạng 1 và 3: DCG = 1 + 1/2 = 1,5; IDCG ≈ 1,63



nDCG ≈ **0,36**

hạng 9 và 10: DCG ≈ 0,59

Độ đo nhạy với **thứ hạng**, đúng mục tiêu tối ưu của reranker.

Giao thức đánh giá

Mọi reranker xếp lại **cùng một danh sách BM25 top-100**, giống bảng của Abdallah et al. (EMNLP Findings 2025: 22 phương pháp, 40 biến thể). Nhờ đó kết quả của nhóm so sánh trực tiếp được với số liệu đã công bố.

Kiểm định ý nghĩa thống kê

Paired bootstrap 10.000 lần lấy mẫu lại, hiệu chỉnh Holm–Bonferroni, $p < 0,05$. Mọi kết luận “A hơn B” đều kèm kiểm định.

Nguồn: src/eval/ir_metrics.py; Abdallah et al. 2025, arXiv:2508.16757.

Hai nguồn sai lệch khi đánh giá reranker

NGUỒN 1 Định dạng đầu vào không thống nhất

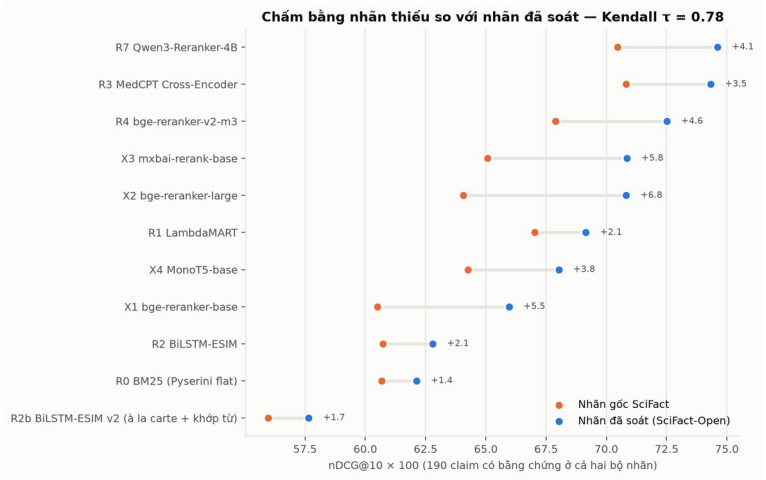
Nhóm tái lập (reproduce) kết quả công bố trước khi so sánh. BM25 khớp chính xác với bài báo (59,47 và 67,89).

bge-reranker-v2-m3 trên TREC-COVID:

Định dạng đầu vào	nDCG@10
Tiêu đề + abstract	**78,57**
Chỉ abstract	74,26
Số công bố trong bài báo	74,79

→ Bảng công bố **trộn lẫn hai định dạng đầu vào** giữa các dòng. Riêng yếu tố này đã gây chênh lệch khoảng **4 điểm nDCG@10**, lớn hơn khoảng cách giữa nhiều mô hình.

NGUỒN 2 Nhãn không đầy đủ (incomplete judgments)



JUDGED@10 CỦA BM25

91%
TREC-COVID

30%
NFCorpus

8,8%
SciFact

- SciFact-Open: chuyên gia chú giải bổ sung, số cặp (claim, bằng chứng) **209 → 460**. Đánh giá lại: cross-encoder **+3,5 đến +6,8**, BM25 chỉ +1,4.
- **Qwen3 và MedCPT hoán đổi hạng 1**; **6 cặp hệ thống đảo thứ hạng** (Kendall τ = 0,78, 11 hệ thống).
- TREC-COVID chỉ dùng qrels vòng 1: τ = 0,56, **17 cặp đảo thứ hạng** (13 hệ thống).

Nguồn: report/tables/e0_reproduction.md; report/tables/e3_labels.md; results/data_report/corpus_stats.json; hình report/figures/fig_e3_scifact_open.png.

Ba bộ dữ liệu, ba dạng truy vấn, ba nguồn nhãn

TREC-COVID

DẠNG TRUY VẤN

Câu hỏi ngôn ngữ tự nhiên

50 truy vấn

171.331 tài liệu trong kho

Độ dài truy vấn: 10,6 từ (TB)

Tài liệu liên quan / truy vấn: 493,5

Mức nhãn: 0 / 1 / 2

Tập huấn luyện: không có

Nguồn nhãn: NIST, 5 vòng chấm

BM25 Recall@100: 0,109

NFCorpus

DẠNG TRUY VẤN

Từ khóa (trung vị 2 từ)

323 truy vấn

3.633 tài liệu trong kho

Độ dài truy vấn: 3,3 từ (trung vị 2)

Tài liệu liên quan / truy vấn: 38,2

Mức nhãn: 1 / 2

Tập huấn luyện: 2.586 truy vấn

Nguồn nhãn: tự động từ hyperlink

BM25 Recall@100: 0,246

SciFact

DẠNG TRUY VẤN

Mệnh đề khoa học (claim)

300 truy vấn

5.183 tài liệu trong kho

Độ dài truy vấn: 12,6 từ (TB)

Tài liệu liên quan / truy vấn: 1,1

Mức nhãn: nhị phân

Tập huấn luyện: 632 claim

Nguồn nhãn: chuyên gia chú giải

BM25 Recall@100: 0,925

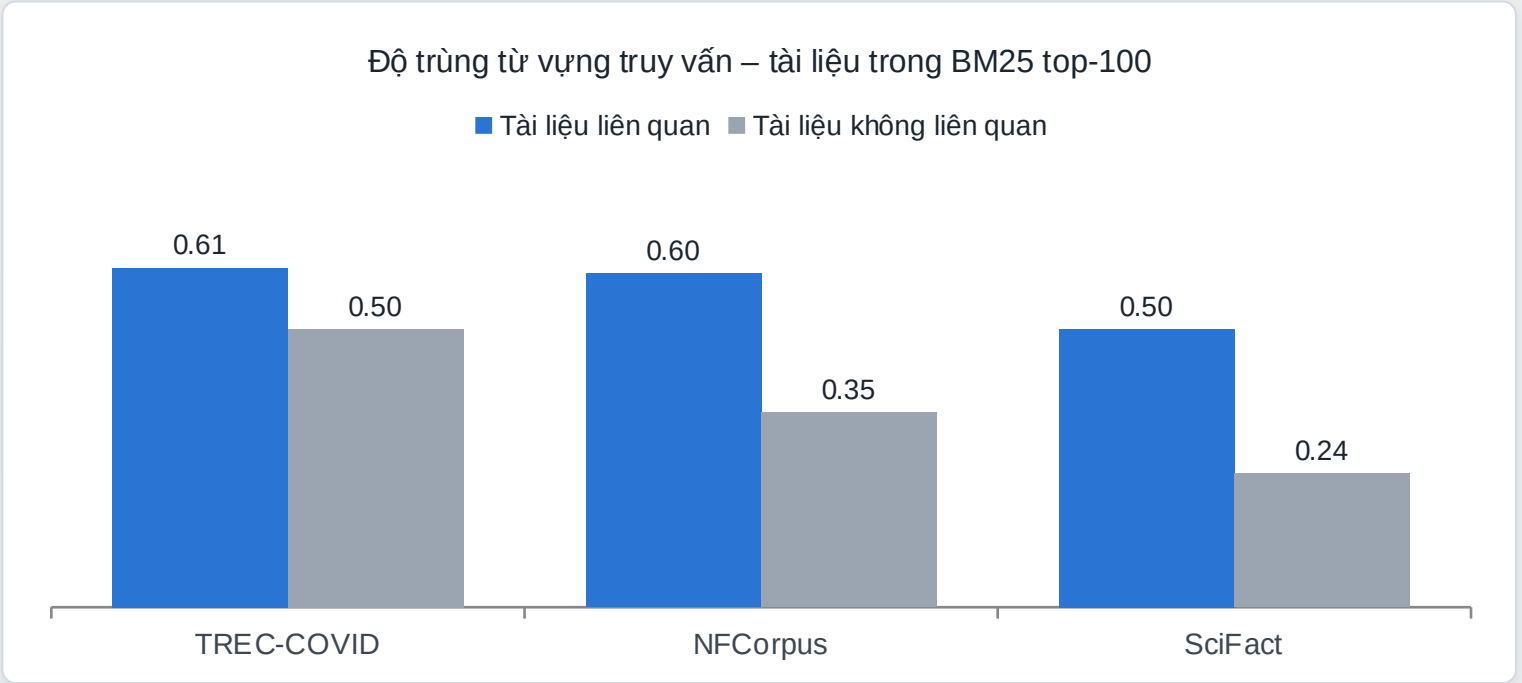
Nguồn: results/data_report/corpus_stats.json, splits.json; Thakur et al. 2021 (BEIR).

Ba phát hiện từ ngữ liệu

1. **Từ vựng trùng khớp phân biệt kém trên TREC-COVID.** Tỷ lệ từ truy vấn có trong tài liệu liên quan / không liên quan: 0,61 / 0,50, so với 0,60 / 0,35 (NFCorpus) và 0,50 / 0,24 (SciFact).

2. **Số tài liệu liên quan chênh hơn 400 lần.** 493,5 / 38,2 / 1,1 mỗi truy vấn. BM25 Recall@100 trên TREC-COVID chỉ 0,109, nhưng top-100 vẫn đủ tài liệu đúng cho top-10 (cận trên 97,48).

3. **Bẫy dữ liệu.** 24,6% tài liệu TREC-COVID không có abstract; 78% truy vấn TREC-COVID chứa từ OOV với BioWordVec; 70/323 truy vấn NFCorpus không có tài liệu liên quan trong top-100.



Độ trùng = tỷ lệ từ của truy vấn xuất hiện trong tài liệu, trung bình trên các tài liệu liên quan (xanh) và không liên quan (xám) trong 100 ứng viên BM25. Chênh lệch nhỏ → khớp từ khó tách tài liệu đúng.

Ví dụ bẫy · SciFact: hai claim gần trùng nhưng ngược nghĩa (TF-IDF cosine 0,90)
train: "…ND3 and ND6 **prevents** TDP-43-induced neuronal loss."
test: "…ND3 and ND6 **leads to increased** TDP-43-induced neuronal loss."

Ba bộ kiểm tra ba năng lực khác nhau: hiểu ngữ nghĩa khi từ vựng trùng nhiều (TREC-COVID), xử lý truy vấn rất ngắn (NFCorpus), suy luận trên mệnh đề khoa học (SciFact).

Nguồn: results/data_report/corpus_stats.json, bilstm_oov.json, splits.json; report/figures/fig_data_lexical_overlap.png; cận trên oracle: phụ lục A11.

Đặc điểm ngữ liệu quyết định thiết kế

Quan sát từ ngữ liệu	Quyết định thiết kế
Bảng công bố (Abdallah et al. 2025) dùng BM25 top-100 trên đúng ba bộ này	Cố định BM25 top-100 cho mọi reranker; tái lập BM25 và 5 reranker có trong bảng trước khi so sánh
24,6% tài liệu TREC-COVID không có abstract	Một định dạng đầu vào cho mọi reranker: “tiêu đề. abstract”
TREC-COVID không có tập huấn luyện	LambdaMART, BiLSTM-ESIM học trên NFCorpus + SciFact, chạy zero-shot trên TREC-COVID
78% truy vấn TREC-COVID chứa từ OOV (covid-19, sars-cov-2)	BiLSTM-ESIM v2: vector à la carte cho từ OOV + kênh khớp từ chính xác
Claim train–test gần trùng (TF-IDF cosine > 0,9)	Loại 19 truy vấn khỏi train; chọn siêu tham số trên dev, test chỉ dùng để báo cáo
Judged@10 thấp (30% NFCorpus, 8,8% SciFact); 70/323 truy vấn NFCorpus không có tài liệu liên quan trong top-100	Báo Judged@10 và cận trên oracle; đánh giá lại bằng SciFact-Open và qrels theo vòng

Nguyên tắc đánh giá

Không chấm tay, không dùng LLM làm người chấm: mọi nhãn đều có sẵn (NIST, chuyên gia, tự động từ hyperlink).

Chia tập

NFCorpus: train 2.586 / dev 324 / test 323. SciFact: train 632 / dev 162 / test 300. TREC-COVID: chỉ có test (50).

Nguồn: results/data_report/splits.json, corpus_stats.json, bilstm_oov.json; report/tables/e0_reproduction.md; NLP_PROJECT_PLAN.md mục 4.

Pointwise: chấm điểm độc lập từng tài liệu

Phương pháp	Năm	Biểu diễn đầu vào	Hàm điểm s(q, d)	Huấn luyện	Độ trễ/truy vấn	TB 3 bộ	Topic 26
Chưa rerank (BM25)	—	—	—	—	—	53,18	55
LambdaMART	2010	11 đặc trưng thủ công	Tổng 1.000 cây hồi quy	LambdaRank, nhãn trong miền	≈ 0 + đặc trưng	61,00	51
BiLSTM-ESIM	2017	Word embedding tĩnh	Soft alignment → MLP	Softmax 1+7, học từ đầu	0,06 s	51,38	37
Cross-encoder (bge-v2-m3)	2019→	Ngữ cảnh tiền huấn luyện	$w^T h$[CLS]	Fine-tune rerank tổng quát	2,3 s	62,08	100
MonoT5	2020	Seq2seq (T5)	log P(“true”)	MS MARCO	4,3 s	60,79	86
MedCPT	2023	Cross-encoder	$w^T h$[CLS]	Log tìm kiếm PubMed	0,64 s	61,02	3 (từ khóa: 40)
Qwen3-Reranker-4B	2025	LLM decoder 4B	z_yes − z_no	Instruction mặc định, zero-shot	25,0 s	**67,24**	100

BA ĐIỀU RÚT RA

1 Tiền huấn luyện tạo bước nhảy

BiLSTM-ESIM học từ đầu: 51,38, thấp hơn cả chưa rerank (53,18). Cross-encoder tiền huấn luyện, zero-shot: 57–64. LLM: 67,24.

2 Dữ liệu học khớp dạng truy vấn

MedCPT học từ log tìm kiếm PubMed (từ khóa): topic 26 chỉ đạt 3; đổi sang truy vấn từ khóa của NIST: 40 (TREC-COVID: 68,79 → 75,43).

3 Chất lượng cao nhất, chi phí cao nhất

Qwen3-Reranker-4B tốt nhất nhóm pointwise nhưng cần 100 lượt forward của mô hình 4B: 25 s/truy vấn, so với 2,3 s của bge-v2-m3.

Nguồn: report/tables/e1_main.md, e2_metadata.md, e4_cost.md; results/e1/e1_per_query.json. Chi tiết từng phương pháp: phụ lục.

PAIRWISE · SETWISE

Pairwise và setwise: so sánh tương đối giữa các ứng viên

PRP-ALLPAIR

So mọi cặp, hỏi cả hai chiều

4.950

cặp với k = 100

Điểm = số trận thắng. Chi phí O(k²).

PRP-SORTING

Sắp xếp bằng phép so cặp (heap sort)

O(k log k)

lượt so sánh

Ít lượt hơn all-pairs, nhưng phải chạy tuần tự.

PRP-SLIDING-K

K lượt nổi bọt để lấy top-K

O(K·k)

lượt so sánh, K = 10

Chỉ cần đúng ở top-K.

SETWISE (2024)

Chọn tài liệu tốt nhất trong nhóm c tài liệu

62,27

TB nDCG@10 · Flan-T5-XXL (công bố)

Mỗi lượt so c tài liệu → ít lượt LLM hơn pairwise.

Đặc điểm của cách tiếp cận

1. **Ưu điểm:** chỉ cần so sánh tương đối “A hay B liên quan hơn”, không cần thang điểm tuyệt đối.

2. **Hạn chế:** chi phí tăng nhanh theo k; kết quả so cặp có thể không bắc cầu (A ≻ B ≻ C ≻ A); nhạy với thứ tự A, B trong prompt.

3. **Trong thí nghiệm:** nhóm không chạy pairwise/setwise vì chi phí API, chỉ dẫn số công bố. Jev có chế độ pairwise: hướng mở rộng.

Nguồn: Qin et al. 2023 (PRP: Allpair, Sorting, Sliding-K); Zhuang et al. 2024 (Setwise); Abdallah et al. 2025 (bảng 3).

LISTWISE

Listwise: LLM sinh trực tiếp hoán vị bằng cửa sổ trượt

- **Listwise (RankGPT, 2023):** đưa LLM một cửa sổ w ứng viên đã đánh số; LLM sinh trực tiếp hoán vị "[3] > [1] > …". Danh sách dài hơn cửa sổ thì trượt từ cuối danh sách lên, để tài liệu tốt "nổi" dần lên đầu.

```
for (i, j) in (80,100), (70,90), …, (0,20):
    π ← LLM(q, d[i:j])     # hoán vị 20 ứng viên
    d[i:j] ← π(d[i:j])     # top-10 đi tiếp lượt sau
# k=100, w=20, s=10 → (k − w)/s + 1 = 9 lượt tuần tự
```

Biến thể: RankGPT zero-shot (chỉ prompt); RankZephyr 7B (LLM mã nguồn mở); ListT5 (xếp theo nhóm nhỏ, tournament sort).

Cài đặt của nhóm (GPT-6 Luna): prompt hoán vị của RankGPT, đoạn văn cắt 300 từ, đầu ra JSON (structured outputs); ID thiếu nối vào cuối, ID trùng bị loại.

Model	Suy luận	TB	Nguồn
RankGPT gpt-3.5	listwise	60,91	công bố
RankZephyr 7B	listwise	64,14	công bố
RankGPT gpt-4 (chỉ top-30)	listwise	66,31	công bố
ListT5-3B	listwise	66,47	công bố
GPT-6 Luna	**listwise**	**67,94**	**nhóm**

GPT-6 Luna: 85,45 / 38,60 / 79,77, cao nhất bảng.

29 s
/truy vấn (9 lượt tuần tự)

5,61 USD
/1.000 truy vấn

56
Topic 26 (≈ chưa rerank)

TOPIC 26
nDCG@10 (0–100) · chưa rerank: 55

LambdaMART	BiLSTM-ESIM	bge-v2-m3	MedCPT	MonoT5	Qwen3	GPT-6 Luna	Jev
51	37	100	3 (kw 40)	86	100	56	?

Nguồn: report/tables/e1_main.md, e4_cost.md; results/e1/luna_run_summary.json; Sun et al. 2023 (RankGPT); Pradeep et al. 2023 (RankZephyr); Yoon et al. 2024 (ListT5); Abdallah et al. 2025.

LISTWISE · MỘT LƯỢT

Jev (2026): ra quyết định trực tiếp, không sinh văn bản

Jev của TypeSafe AI, công bố 15/09/2026. TypeSafe gọi đây là **“System One model”**, theo khái niệm tư duy nhanh (System 1) của Kahneman.

Cơ chế: toàn bộ ứng viên nằm trong một ngữ cảnh; mô hình trả về $s_i = P(y_i = \text{true} \mid q, d_1 \ldots d_k)$ đã hiệu chỉnh cho từng ứng viên trong một lượt suy luận, không sinh chuỗi hoán vị.

```
state     = { query, documents: { doc_0 … doc_99 } }
questions = { doc_i: Noul("Is documents.doc_i
                relevant to query?",
                true: "…", false: "…") }
answers   = Jev(state, questions)  # một lượt
điểm_i    = P(true) đã hiệu chỉnh → sắp xếp giảm dần
```

Mô hình hộp đen: không công bố kiến trúc, số tham số, dữ liệu huấn luyện.

	RankGPT / Luna	Qwen3	Jev
Ngữ cảnh mỗi lượt	20 tài liệu / lượt	1 tài liệu	**Toàn bộ danh sách**
Đầu ra	Chuỗi hoán vị (cần parse)	logit yes − no	**P(true) từng tài liệu**
Số lượt / truy vấn	9 tuần tự	100	**1 (chia lô khi quá dài)**
Tiêu chí	Prompt	Instruction cố định	**Tiêu chí ngôn ngữ tự nhiên, không cần huấn luyện lại**

TypeSafe công bố: huấn luyện bằng RLCD (Reinforcement Learning for Calibrated Decisions); độ trễ 70–500 ms mỗi request; 0,042 USD / 1 triệu token đầu vào, token đầu ra miễn phí.

TOPIC 26
nDCG@10 (0–100) · chưa rerank: 55

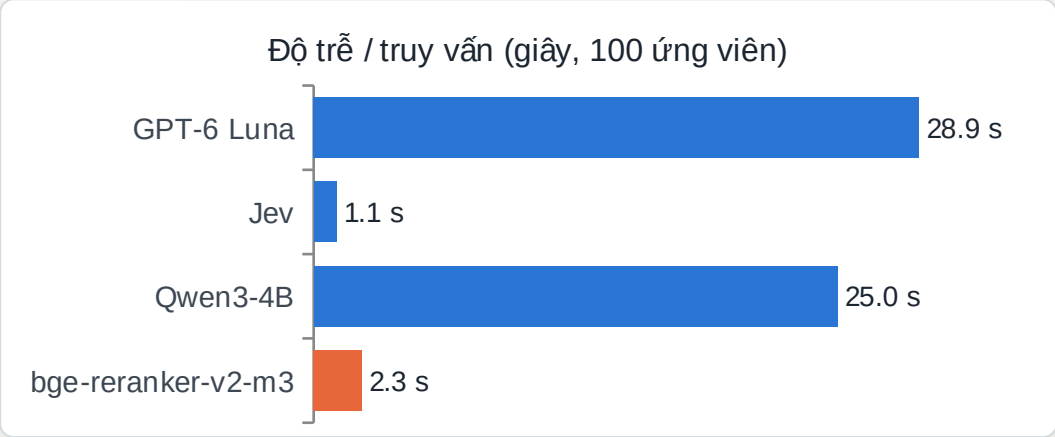
LambdaMART	BiLSTM-ESIM	bge-v2-m3	MedCPT	MonoT5	Qwen3	GPT-6 Luna	Jev
51	37	100	3 (kw 40)	86	100	56	?

Nguồn: docs.typesafe.ai/concepts/system-one; typesafe.ai/blog/introducing-system-one-models-and-jev; thư viện jev-reranker 0.1.2 (src/rerank/jev.py).

So sánh: chất lượng ngang nhau, độ trễ chênh khoảng 25 lần

Model	Suy luận	TREC-COVID	NFCorpus	SciFact	TB	Độ trễ/truy vấn	USD / 1.000 truy vấn
GPT-6 Luna	listwise, 9 lượt	85,45	38,60	79,77	67,94	28,9 s	5,61
Jev	**listwise, 1 lượt**	**84,41**	**38,24**	**79,14**	**67,27**	**1,1 s**	**1,62**
Qwen3-4B	pointwise	85,00	37,37	79,35	67,24	25,0 s	2,48*
bge-reranker-v2-m3	pointwise	78,57	33,69	73,99	62,08	2,3 s	0,22*

* mô hình chạy local: USD quy đổi theo giá thuê GPU T4 (ước lượng); API: chi phí thực tế từ log.



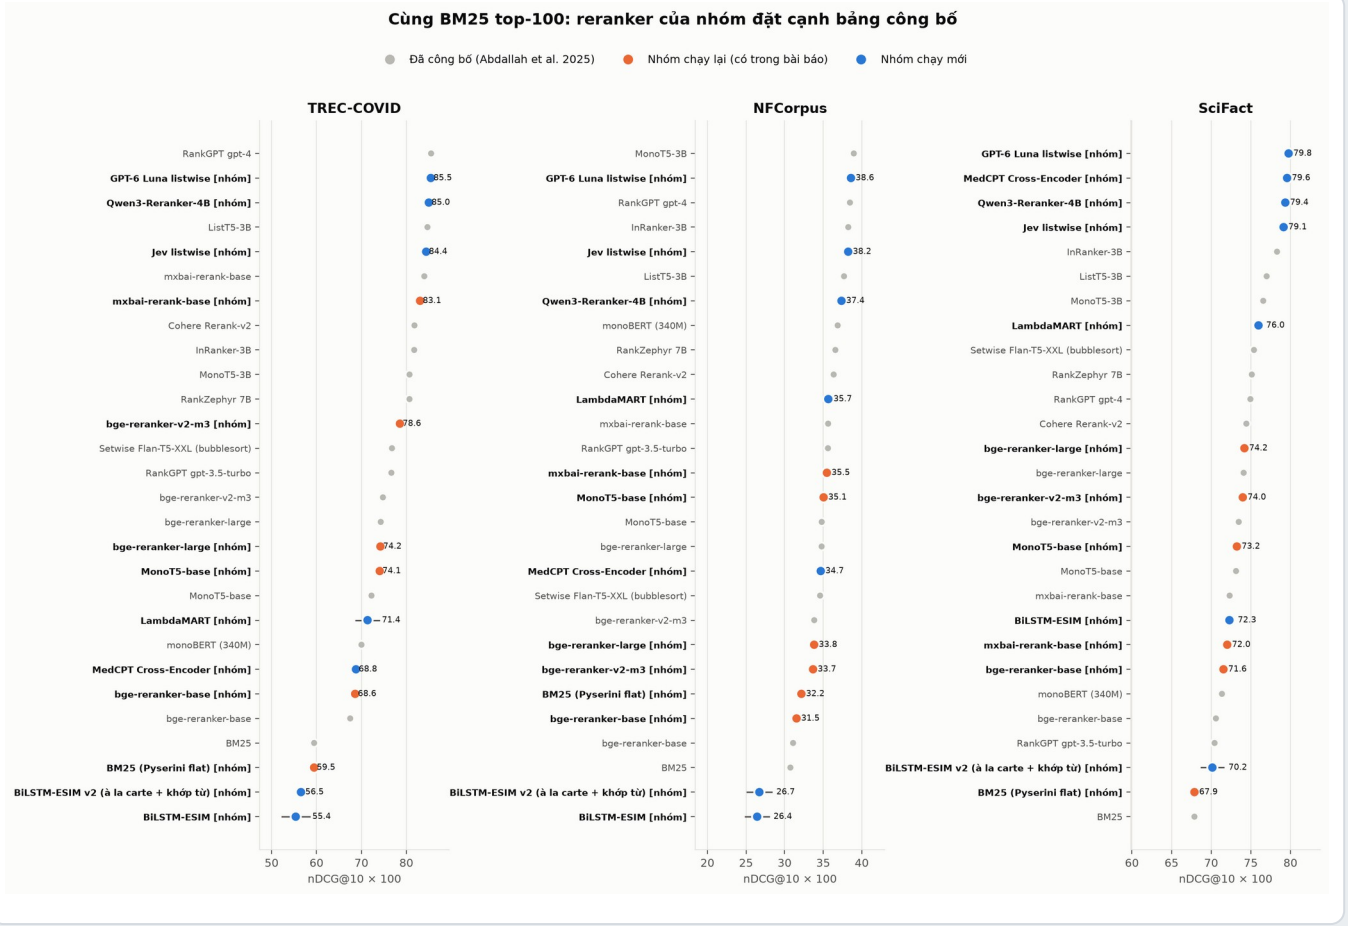
- **Ba mô hình đầu không khác biệt có ý nghĩa thống kê** trên cả 3 bộ (paired bootstrap + Holm). Ngoại lệ duy nhất: Luna vượt Qwen3 trên NFCorpus.
- Jev vượt bge-v2-m3 **4,6–5,8 điểm** (có ý nghĩa thống kê trên NFCorpus và SciFact; TREC-COVID p = 0,08 do chỉ có 50 truy vấn).
- Phiên bản mô hình **jev-1.14.0**: 673 truy vấn, 1.243 request (TB 1,8 request/truy vấn do tự chia lô). Tổng chi phí **1,09 USD**.
- Topic 26: Jev **47**, Luna 56, trong khi các mô hình pointwise đạt 100. Một truy vấn đơn lẻ chưa đủ để kết luận.

TOPIC 26
nDCG@10 (0–100) · chưa rerank: 55

LambdaMART	BiLSTM-ESIM	bge-v2-m3	MedCPT	MonoT5	Qwen3	GPT-6 Luna	Jev
51	**37**	**100**	**3 (kw 40)**	**86**	**100**	**56**	**47**

Nguồn: report/tables/e1_main.md; report/tables/e4_cost.md; results/api_logs/jev__*.jsonl; kiểm định bằng src/eval/significance.py trên results/e1/e1_per_query.json.

Tiến bộ không đơn điệu theo thời gian



Xám: đã công bố (Abdallah et al. 2025) · Cam: nhóm tái lập · Xanh: kết quả mới của nhóm

1 **Mới hơn chưa chắc tốt hơn.** BiLSTM (2017) thấp hơn LambdaMART (2010) và cả mốc chưa rerank. Bước nhảy đến từ **tiền huấn luyện**, không phải từ bản thân kiến trúc neural.

2 **In-domain chưa chắc tốt hơn.** MedCPT thấp hơn bge trên truy vấn dạng câu hỏi, cao hơn trên claim. Phân phối truy vấn khi huấn luyện mới là yếu tố quyết định.

3 **Listwise chưa chắc tốt hơn pointwise.** Luna, Jev (listwise) và Qwen3 (pointwise) không khác biệt có ý nghĩa thống kê. Chiến lược suy luận chủ yếu thay đổi **chi phí**.

Abdallah et al. (2025): reranker dựa trên LLM mạnh với truy vấn quen thuộc, nhưng khả năng tổng quát hóa sang truy vấn mới dao động nhiều; mô hình gọn nhẹ cạnh tranh về hiệu năng (efficiency).

Nguồn: report/figures/fig_e1_ranking.png; Abdallah et al. 2025 (abstract).

KẾT LUẬN

Ba kết luận chính

1

Reranking tồn tại do đánh đổi chi phí và chất lượng

BM25 truy xuất toàn kho trong 16 ms; reranker neural chấm toàn kho mất từ 18 phút đến 14 giờ. Chỉ rerank 100 ứng viên đã thu hẹp tới **68%** khoảng cách đến cận trên oracle.

2

Ba cách tiếp cận khác nhau chủ yếu ở chi phí

Ở nhóm dẫn đầu, listwise (Luna, Jev) và pointwise (Qwen3) ngang nhau về chất lượng; độ trễ chênh **1 s so với 29 s**. Chất lượng đến từ tiền huấn luyện (51 → 57–64 → ≈67) và dữ liệu khớp dạng truy vấn (MedCPT: 3 → 40).

3

So sánh reranker cần cùng giao thức đánh giá

Cùng tập ứng viên, cùng định dạng đầu vào, biết rõ độ phủ nhãn (Judged@k). Định dạng đầu vào gây lệch **4 điểm**; nhãn không đầy đủ làm đảo thứ hạng **6 cặp hệ thống**.

Cảm ơn thầy cô và các bạn · Hỏi đáp

BM25: bộ truy xuất tầng một và mốc chưa rerank

Nguyên lý: mô hình xác suất (Probabilistic Relevance Framework) trên biểu diễn bag-of-words: điểm là tổng đóng góp của các từ truy vấn xuất hiện trong tài liệu.

$$s(q,d) = \sum_{t \in q} \mathrm{IDF}(t) \cdot \frac{\mathrm{tf}(t,d)\,(k_1+1)}{\mathrm{tf}(t,d) + k_1\left(1 - b + b\,\frac{|d|}{\mathrm{avgdl}}\right)}$$

$$\mathrm{IDF}(t) = \ln\left(1 + \frac{N - \mathrm{df}(t) + 0{,}5}{\mathrm{df}(t) + 0{,}5}\right)$$

- tf(t,d): tần suất của t trong d; |d|/avgdl: độ dài tương đối của d.
- df(t): số tài liệu chứa t trong kho N tài liệu; từ hiếm có IDF cao.
- k_1 = 0,9: bão hòa TF; b = 0,4: chuẩn hóa độ dài (mặc định Pyserini).

Huấn luyện
Không huấn luyện; k_1, b cố định.

Chi phí suy luận
Duyệt posting list trên chỉ mục ngược: 16 ms/truy vấn trên toàn kho.

TREC-COVID	NFCorpus	SciFact	TB 3 bộ
59,47	32,18	67,89	53,18

Vai trò trong thí nghiệm

Là **bộ truy xuất tầng một** (tạo 100 ứng viên) và **mốc chưa rerank**; không phải reranker được so sánh. Nó quyết định cận trên oracle (slide 5).

Hạn chế: không nắm bắt ngữ nghĩa (lệch từ vựng); chỉ dùng một tín hiệu liên quan duy nhất.

Nguồn: report/tables/e1_main.md; Robertson et al., TREC-3 (1994).

POINTWISE

LambdaMART (2010): learning-to-rank trên đặc trưng thủ công

Nguyên lý: mô hình cộng tính gồm M cây hồi quy (gradient boosting, MART); mỗi cây khớp λ-gradient của LambdaRank: gradient RankNet nhân với |ΔnDCG| khi hoán đổi một cặp tài liệu.

11 đặc trưng φ(q, d): điểm và hạng BM25, TF-IDF cosine, độ tương đồng MedCPT bi-encoder (thô và chuẩn hóa z), độ trùng từ với truy vấn và với tiêu đề, độ dài tài liệu và truy vấn, có tiêu đề hay không.

Mô hình $$s(q,d) = F_M(\mathbf{x}) = \sum_{m=1}^{M} \eta\, h_m(\mathbf{x}), \quad \mathbf{x} = \phi(q,d) \in \mathbb{R}^{11}$$

λ-gradient $$\lambda_{ij} = \frac{-\sigma |\Delta \mathrm{nDCG}_{ij}|}{1 + e^{\sigma(s_i - s_j)}}, \quad \lambda_i = \sum_{j:\, y_i > y_j} \lambda_{ij} - \sum_{j:\, y_j > y_i} \lambda_{ji}$$

Huấn luyện: LightGBM lambdarank, tối đa M = 1.000 cây, η = 0,05, 31 lá/cây; early stopping theo nDCG@10 trên dev; dữ liệu NFCorpus + SciFact, 3 seed. Suy luận **pointwise**: mỗi tài liệu một lượt tính F(x).

TREC-COVID	NFCorpus	SciFact	TB 3 bộ
71,37	35,67	75,97	61,00

+8 điểm so với chưa rerank · cải thiện ở **33/50** truy vấn TREC-COVID.

68% feature importance (gain) thuộc về **đặc trưng MedCPT**, một mô hình neural.

Hạn chế: chất lượng bị chặn bởi feature engineering: mô hình chỉ tốt bằng các đặc trưng do con người thiết kế.

TOPIC 26
nDCG@10 (0–100) · chưa rerank: 55

LambdaMART	BiLSTM-ESIM	bge-v2-m3	MedCPT	MonoT5	Qwen3	GPT-6 Luna	Jev
51	37	100	3 (kw 40)	86	100	56	47

Nguồn: report/tables/e1_main.md; results/e1/lambdamart_train.json; report/tables/error_cases.md.

POINTWISE

BiLSTM-ESIM (2017): mô hình tương tác với soft alignment

Nguyên lý: mô hình tương tác (interaction-based). a, b: chuỗi embedding BioWordVec 200 chiều (đóng băng) của truy vấn (≤ 64 token) và tài liệu (≤ 256 token).

Mã hóa	$\bar{a}_i = \mathrm{BiLSTM}(a)_i, \quad \bar{b}_j = \mathrm{BiLSTM}(b)_j$
Căn chỉnh mềm	$e_{ij} = \bar{a}_i^\top \bar{b}_j, \quad \tilde{a}_i = \sum_j \frac{\exp(e_{ij})}{\sum_k \exp(e_{ik})} \bar{b}_j$
Tăng cường	$m_i^a = [\bar{a}_i;\ \tilde{a}_i;\ \bar{a}_i - \tilde{a}_i;\ \bar{a}_i \odot \tilde{a}_i]$
Tổng hợp	$v = \mathrm{BiLSTM}(\mathrm{ReLU}(Wm)), \quad s(q,d) = \mathrm{MLP}\left(\left[v^a_{\mathrm{avg}};\ v^a_{\mathrm{max}};\ v^b_{\mathrm{avg}};\ v^b_{\mathrm{max}}\right]\right)$

Huấn luyện: softmax cross-entropy trên nhóm 1 positive + 7 negative (lấy từ BM25 top-100); Adam, lr $4 \cdot 10^{-4}$, early stopping theo nDCG@10 trên dev; **huấn luyện từ đầu** (encoder không được tiền huấn luyện), 3 seed.

TREC-COVID	NFCorpus	SciFact	TB 3 bộ
55,38	26,44	72,30	51,38

Thấp hơn mốc chưa rerank (53,18). Chỉ cải thiện trên SciFact.

Phân tích nguyên nhân

78%
truy vấn TREC-COVID chứa từ OOV

≈2 từ
độ dài trung vị truy vấn NFCorpus

≈3.200
truy vấn huấn luyện

Hạn chế: học được biểu diễn end-to-end, nhưng thiếu tri thức tiền huấn luyện.

TOPIC 26
nDCG@10 (0–100) · chưa rerank: 55

LambdaMART	BiLSTM-ESIM	bge-v2-m3	MedCPT	MonoT5	Qwen3	GPT-6 Luna	Jev
51	37	100	3 (kw 40)	86	100	56	47

Nguồn: report/tables/e1_main.md; report/tables/improvements.md; results/data_report/bilstm_oov.json; Chen et al., ACL 2017.

POINTWISE

Cross-encoder (2019 →): tiền huấn luyện và mã hóa chung

Bi-encoder: mã hóa độc lập

$$s(q,d) = E_Q(q)^\top E_D(d)$$

Hai encoder độc lập; embedding tài liệu tính trước (offline) → phù hợp **tầng một**.

Cross-encoder: mã hóa chung

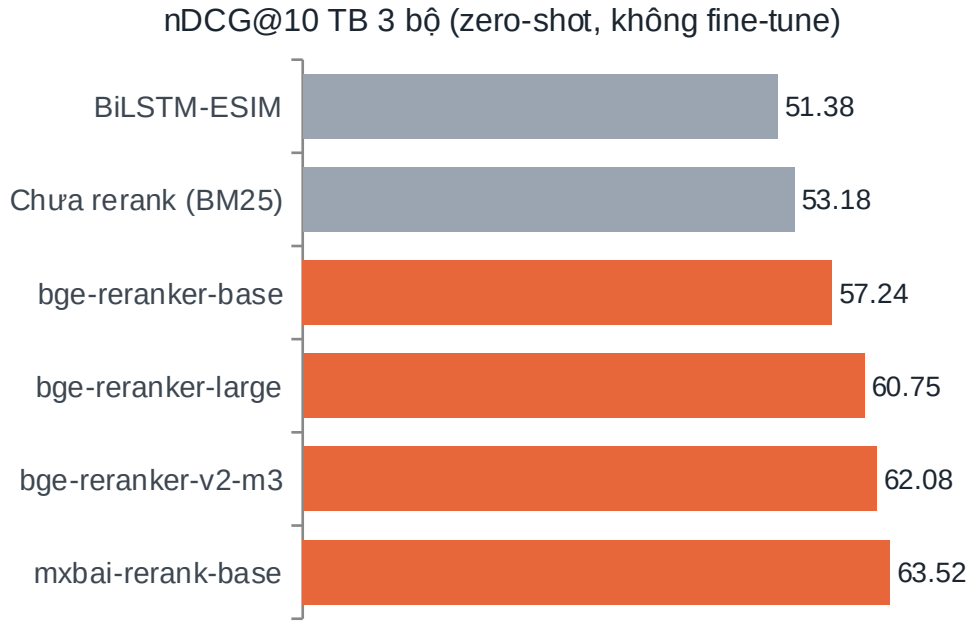
$$\mathbf{h} = \mathrm{Enc}([\mathrm{CLS}]\ q\ [\mathrm{SEP}]\ d\ [\mathrm{SEP}])$$

$$s(q,d) = \mathbf{w}^\top \mathbf{h}_{[\mathrm{CLS}]} + b$$

Self-attention giữa mọi token của q và d; một forward pass cho mỗi cặp → phù hợp **tầng hai**.

Huấn luyện: ① tiền huấn luyện tự giám sát trên văn bản không nhãn (BERT: masked language modeling); ② fine-tune trên các cặp (truy vấn, đoạn văn) có nhãn; monoBERT dùng cross-entropy pointwise trên MS MARCO.

Chi phí suy luận: 100 forward pass theo batch trên GPU, đầu vào cắt 512 token; self-attention $O((|q| + |d|)^2)$ cho mỗi cặp; 0,6–2,3 s/truy vấn.



bge-v2-m3 cải thiện so với chưa rerank ở **40/50** truy vấn TREC-COVID. mxbai **base** vượt bge **large**: nhiều tham số hơn không đảm bảo chất lượng cao hơn.

TOPIC 26
nDCG@10 (0–100) · chưa rerank: 55

LambdaMART	BiLSTM-ESIM	bge-v2-m3	MedCPT	MonoT5	Qwen3	GPT-6 Luna	Jev
51	37	100	3 (kw 40)	86	100	56	47

Nguồn: report/tables/e1_main.md; report/tables/e4_cost.md; Nogueira & Cho 2019 (monoBERT).

MedCPT (2023): dữ liệu huấn luyện và lệch phân phối truy vấn

MedCPT-CE: cross-encoder nền PubMedBERT, **huấn luyện trên 255 triệu lượt click từ log tìm kiếm PubMed** (cặp truy vấn–bài báo; Jin et al., 2023).

TREC-COVID	NFCorpus	SciFact	TB 3 bộ
68,79	34,68	79,58	61,02

- SciFact **79,58**: cao hơn mọi kết quả đã công bố.
- TREC-COVID **68,79**: thấp hơn bge-v2-m3 (78,57) gần 10 điểm.

Đây là lời giải thích cho điểm **3** ở slide 3: truy vấn PubMed **ở dạng từ khóa**, còn topic 26 là câu hỏi ngôn ngữ tự nhiên.

Cùng 100 ứng viên, chỉ thay đổi dạng truy vấn đầu vào

Câu hỏi tự nhiên (mặc định)

3

Topic 26

TREC-COVID: **68,79**

→

Truy vấn từ khóa (NIST)

40

Topic 26

TREC-COVID: **75,43** (+6,6)

Reranker mạnh trên đúng phân phối truy vấn đã huấn luyện. Dạng truy vấn quan trọng hơn miền chuyên ngành (domain).

TOPIC 26
nDCG@10 (0–100) · chưa rerank: 55

LambdaMART	BiLSTM-ESIM	bge-v2-m3	MedCPT	MonoT5	Qwen3	GPT-6 Luna	Jev
51	37	100	3 (kw 40)	86	100	56	47

Nguồn: report/tables/e1_main.md; report/tables/e2_metadata.md; Jin et al. 2023 (MedCPT).

POINTWISE

MonoT5 và Qwen3: rerank bằng xác suất sinh token

MonoT5 (2020)

Quy rerank về bài toán sinh một token nhị phân (seq2seq).

```
Đầu vào: "Query: q  Document: d  Relevant:"
```

$$s(q,d) = \log \frac{e^{z_{\text{true}}}}{e^{z_{\text{true}}} + e^{z_{\text{false}}}}$$

Huấn luyện: fine-tune T5 (seq2seq) trên MS MARCO để sinh token “true” / “false”; z là logit ở bước giải mã đầu tiên.

TREC-COVID	NFCorpus	SciFact	TB 3 bộ
74,08	35,06	73,24	60,79

Topic 26: **86**

Qwen3-Reranker-4B (2025)

Cùng nguyên lý, với LLM decoder-only 4 tỉ tham số.

```
"Judge whether the Document meets the
 requirements… answer only yes or no"
```

$$s(q,d) = z_{\text{yes}} - z_{\text{no}} = \log \frac{P(\text{yes})}{P(\text{no})}$$

Suy luận: z là logit tại vị trí cuối của prompt (zero-shot, instruction mặc định); 100 forward pass ≈ 25 s/truy vấn trên GPU T4.

TREC-COVID	NFCorpus	SciFact	TB 3 bộ
85,00	37,37	79,35	67,24

Cải thiện so với chưa rerank ở **44/50** truy vấn · Topic 26: **100**

Hạn chế: cả hai vẫn suy luận pointwise. Nếu LLM xét nhiều ứng viên trong cùng một ngữ cảnh thì sao?

TOPIC 26
nDCG@10 (0–100) · chưa rerank: 55

LambdaMART	BiLSTM-ESIM	bge-v2-m3	MedCPT	MonoT5	Qwen3	GPT-6 Luna	Jev
51	37	100	3 (kw 40)	86	100	56	47

Nguồn: report/tables/e1_main.md; report/tables/e4_cost.md; Nogueira et al. 2020; model card Qwen3-Reranker.

Bảng kết quả đầy đủ (nDCG@10 × 100)

Model	TREC-COVID	NFCorpus	SciFact	TB	Nguồn
Chưa rerank (BM25 top-100)	59,47	32,18	67,89	53,18	nhóm
Cận trên oracle (top-100)	**97,48**	**54,39**	**92,65**	**—**	**nhóm, tính 11/11**
LambdaMART	71,37	35,67	75,97	61,00	nhóm (3 seed)
BiLSTM-ESIM	55,38	26,44	72,30	51,38	nhóm (3 seed)
BiLSTM-ESIM v2	56,54	26,73	70,15	51,14	nhóm (3 seed)
MedCPT-CE	68,79	34,68	79,58	61,02	nhóm
bge-reranker-base	68,61	31,55	71,55	57,24	nhóm
bge-reranker-large	74,23	33,83	74,20	60,75	nhóm
bge-reranker-v2-m3	78,57	33,69	73,99	62,08	nhóm
mxbai-rerank-base	83,06	35,48	72,03	63,52	nhóm
MonoT5-base	74,08	35,06	73,24	60,79	nhóm
Qwen3-Reranker-4B	85,00	37,37	79,35	67,24	nhóm
GPT-6 Luna (listwise)	85,45	38,60	79,77	67,94	nhóm (đồng đội chạy)
Jev (listwise)	84,41	38,24	79,14	67,27	nhóm

Model	TREC-COVID	NFCorpus	SciFact	TB	Nguồn
monoBERT	70,01	36,88	71,36	59,42	công bố
MonoT5-3B	80,71	38,97	76,57	65,42	công bố
InRanker-3B	81,75	38,25	78,31	66,10	công bố
Cohere Rerank-v2	81,81	36,36	74,44	64,20	công bố
RankGPT gpt-3.5	76,67	35,62	70,43	60,91	công bố
RankGPT gpt-4 (top-30)	85,51	38,47	74,95	66,31	công bố
RankZephyr 7B	80,70	36,58	75,13	64,14	công bố
ListT5-3B	84,70	37,70	77,00	66,47	công bố
Setwise Flan-T5-XXL	76,8	34,6	75,4	62,27	công bố

Nguồn: report/tables/e1_main.md, e1_full.md; Abdallah et al. 2025.

Độ trễ, chi phí và thắng/thua so với chưa rerank

Độ trễ và chi phí (p50, rerank 100 ứng viên)

Model	Độ trễ (p50)	USD / 1.000 truy vấn
Tầng một BM25 (toàn kho)	16 ms	0
BiLSTM	0,06 s	0,006
MedCPT	0,64 s	0,06
Jev	1,08 s	1,62
mxbai	1,74 s	0,17
bge-v2-m3	2,28 s	0,22
MonoT5	4,32 s	0,42
Qwen3	25,0 s	2,48
Luna	28,9 s	5,61

Chi phí mô hình local là ước lượng theo giá thuê GPU T4; chi phí API là số thực tế từ log.

Thắng / thua so với chưa rerank trên 50 truy vấn TREC-COVID

Model	Thắng	Thua
Luna	45	3
Qwen3	44	3
mxbai	41	6
Jev	41	7
bge-v2-m3	40	7
MonoT5	34	14
LambdaMART	33	17
MedCPT	32	16
BiLSTM	19	31

Nguồn: report/tables/e4_cost.md; results/e1/e1_per_query.json.

Cách tính cận trên oracle và độ trễ BM25

A11 · Cận trên oracle của reranker

Với mỗi truy vấn, sắp xếp 100 ứng viên BM25 theo nhãn qrels (tài liệu chưa đánh giá = 0), rồi tính nDCG@10.

Kết quả: 97,48 / 54,39 / 92,65 (TREC-COVID / NFCorpus / SciFact).

Truy vấn không có tài liệu liên quan trong top-100: 0/50, 70/323 (gồm 15 truy vấn BM25 không trả về kết quả), 21/300.

Tính ngày 11/11 từ results/runs/<bộ>/test/bm25.trec và qrels.

A12 · Độ trễ BM25 và ngoại suy toàn kho

Pyserini, index beir-v1.0.0-trec-covid.flat, 50 truy vấn, 1 luồng, top-100.

p50: 16,4 ms · **tối đa:** 69,4 ms.

Ngoại suy toàn kho = p50 rerank 100 tài liệu × 1.713,31 (= 171.331 / 100). Ước lượng tuyến tính, chỉ để minh họa bậc độ lớn.

Đo ngày 11/11; report/tables/e4_cost.md.

Nguồn: hai số liệu tính riêng ngày 11/11, chưa nằm trong report/tables/.

Lựa chọn reranker khi triển khai: theo ngân sách độ trễ

GẦN NHƯ 0

Không rerank (tầng một)

53,18
TB nDCG@10

Mốc so sánh: thứ tự BM25.

< 1 GIÂY

MedCPT (0,64 s, GPU)

61,02
TB nDCG@10

Nhạy với dạng truy vấn.

1–2 GIÂY

Jev (1,1 s, API) hoặc mxbai (1,7 s, GPU)

67,27 / 63,52
TB nDCG@10

Jev: chất lượng ngang LLM.

XỬ LÝ OFFLINE (BATCH)

GPT-6 Luna, Qwen3

67,94 / 67,24
TB nDCG@10

25–29 s/truy vấn.

Ba tham số thiết kế khác

Độ sâu rerank k: k lớn thì cận trên oracle cao hơn, nhưng chi phí tăng tuyến tính.

Cascade nhiều tầng: cross-encoder cắt 100 ứng viên xuống 20, rồi LLM chỉ rerank top-20 (như RankGPT gpt-4 chỉ xếp top-30). Nhóm chưa đo.

Bảo mật dữ liệu: API (Luna, Jev) gửi văn bản ra bên thứ ba; mô hình local xử lý tại chỗ (on-premise).

Nguồn: report/tables/e4_cost.md; report/figures/fig_e4_pareto.png.

Câu hỏi nghiên cứu còn mở

1. **Cố định mô hình, thay đổi chiến lược suy luận.** Jev hỗ trợ cả listwise lẫn pointwise, cho phép một thí nghiệm có kiểm soát (ước tính khoảng 1,1 USD). Thí nghiệm này cũng giúp lý giải trường hợp topic 26.

2. **Nhãn không đầy đủ với LLM.** Đánh giá lại trên qrels bổ sung của SciFact-Open mới gồm 11 mô hình local, chưa có Luna và Jev.

3. **Nhiễm dữ liệu (data contamination).** Các bộ BEIR công khai từ 2021 nên LLM có thể đã gặp khi huấn luyện. Cần truy vấn mới để kiểm tra (Abdallah et al. 2025: FutureQueryEval).

4. **Tiêu chí liên quan theo từng topic.** Dùng mô tả “thế nào là liên quan” (narrative) của NIST làm tiêu chí cho Jev thay cho tiêu chí chung.

5. **Độ hiệu chỉnh (calibration) của xác suất Jev.** Đối chiếu với qrels bằng reliability diagram; không phát sinh thêm chi phí API.

Nguồn: report/tables/e3_labels.md; scripts/run_api.py --dry-run.