SEMINAR · CS2308

BioRerank: Evaluating Document Reranking Models for Biomedical Information Retrieval

Nhóm 11
Nguyễn Hải Đăng– 26848027
Hoàng Đức Chung– 26848017

Phát biểu bài toán reranking

Ký hiệu

- Kho tài liệu D (TREC-COVID: |D| = 171.331), truy vấn q.
- Bộ truy xuất tầng một R (ở đây là BM25) trả về tập ứng viên $C_q = (d_1, \ldots, d_k)$, với **k = 100 ≪ |D|**.
- Nhãn liên quan rel_q(d) ∈ {0, 1, 2} lấy từ qrels của benchmark; tài liệu chưa đánh giá (unjudged) tính là 0.

Định nghĩa

Reranker là hàm f nhận truy vấn và tập ứng viên, trả về một **hoán vị** của tập đó:

Đầu ra $\pi = f(q, C_q)$

Mục tiêu $f^* = \arg\max_f \mathbb{E}_q[\text{nDCG@10}(\pi, \text{rel}_q)]$

Ràng buộc then chốt: reranker chỉ đổi thứ tự, không thêm và không bớt tài liệu.
→ tồn tại **cận trên oracle** (slide 5).
→ recall của tầng một chặn trên chất lượng của tầng hai.

So sánh với truy xuất tầng một (first-stage retrieval)

	Tầng một (retrieval)	Tầng hai (reranking)
Phạm vi	Toàn bộ kho (10^5–10^6 tài liệu)	k ứng viên (thường 20–1.000)
Ràng buộc	Mã hóa tài liệu offline, tra cứu qua index	Mã hóa chung (truy vấn, tài liệu), chấp nhận chi phí cao
Mục tiêu	Độ phủ: Recall@k	Thứ hạng đầu danh sách: nDCG@10
Ví dụ	BM25, bi-encoder (DPR, MedCPT retriever)	cross-encoder, LLM, Jev

Vì chỉ xử lý 100 tài liệu, reranker dùng được phép tính đắt mà tầng một không kham nổi: **mã hóa chung truy vấn–tài liệu (joint encoding)**.

Nguồn: NLP_PROJECT_PLAN.md mục 5; Abdallah et al. 2025 (thiết lập BM25 top-100).

Cùng tập ứng viên, nDCG@10 dao động từ 3 đến 100

TOPIC 26 · TREC-COVID

"What are the initial symptoms of Covid-19?"

Cùng 100 tài liệu ứng viên (BM25 top-100) cho mọi mô hình.

3 / 100

nDCG@10 của một reranker (tên mô hình: công bố sau)

100 / 100

nDCG@10 của một reranker (tên mô hình: công bố sau)

Thách thức của bài toán xếp hạng

1. **Lệch từ vựng (vocabulary mismatch)**
   "initial symptoms" và "first clinical manifestations": cùng nghĩa, khác từ vựng.

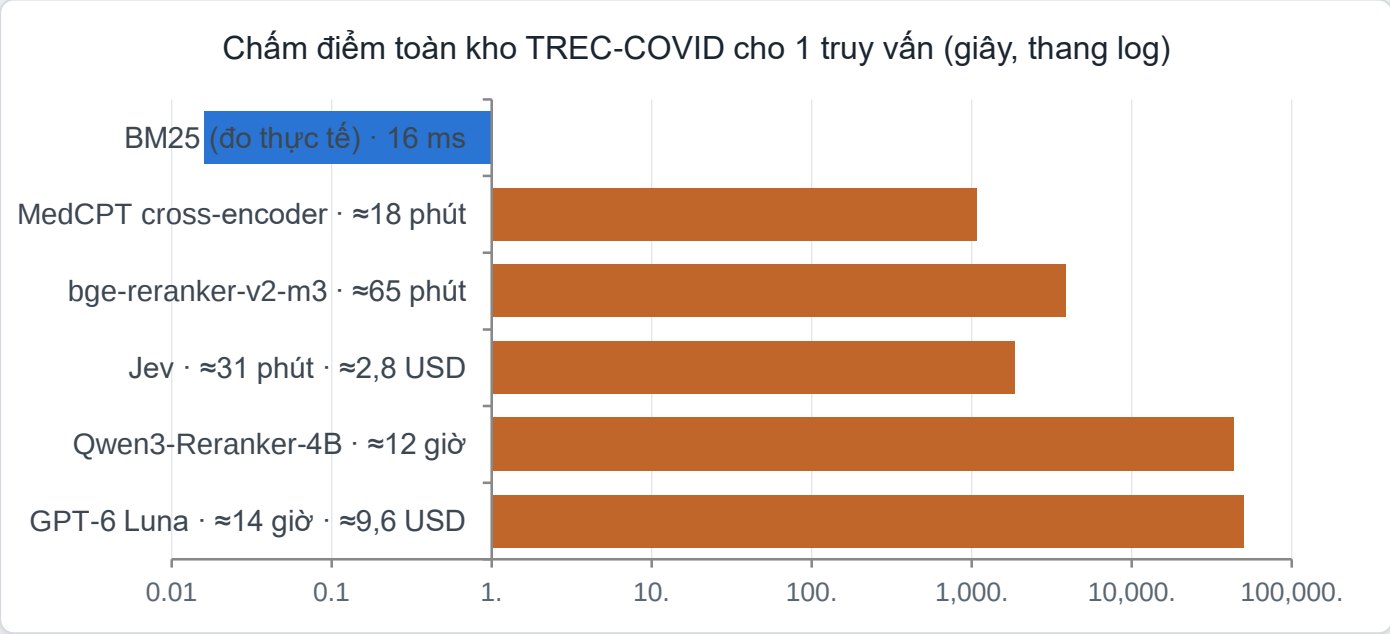
2. **Lệch phân phối truy vấn (distribution shift)**
   Truy vấn là câu hỏi ngôn ngữ tự nhiên, trong khi nhiều mô hình quen với truy vấn từ khóa ("coronavirus early symptoms").

3. **Từ ngoài từ vựng (OOV)**
   "covid-19" không có trong các bộ từ vựng xây dựng trước 2019.

Tập ứng viên cố định → mọi chênh lệch đến từ **bước xếp hạng lại**: reranker.

Nguồn: results/e1/e1_per_query.json (topic 26); data/raw/trec_covid/topics-rnd5.xml.

Đánh đổi giữa chất lượng xếp hạng và chi phí suy luận



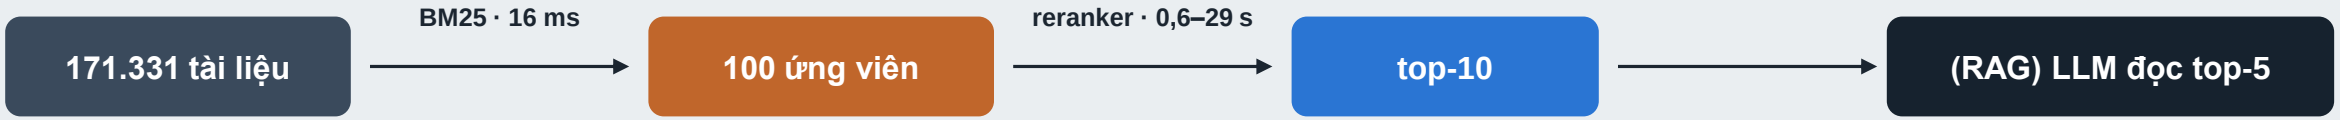
BM25: đo thực tế (trung vị, một luồng CPU). Còn lại: ngoại suy tuyến tính từ độ trễ rerank 100 tài liệu × 1.713.

Vì sao chênh nhau hơn 200 nghìn lần

BM25: chỉ mục ngược (inverted index)
Dựng trước (offline); lúc truy vấn chỉ duyệt posting list của các từ trong truy vấn.

Reranker neural: mã hóa chung (q, d)
Điểm phụ thuộc truy vấn nên không tính trước được; mỗi truy vấn cần một forward pass cho từng tài liệu.

Lời giải: kiến trúc xếp hạng nhiều tầng (multi-stage ranking)



Tầng một **rẻ**: tối ưu **recall** (không bỏ sót tài liệu liên quan).

Tầng hai **đắt**: tối ưu **precision ở top-k**. Tầng này chính là reranker.

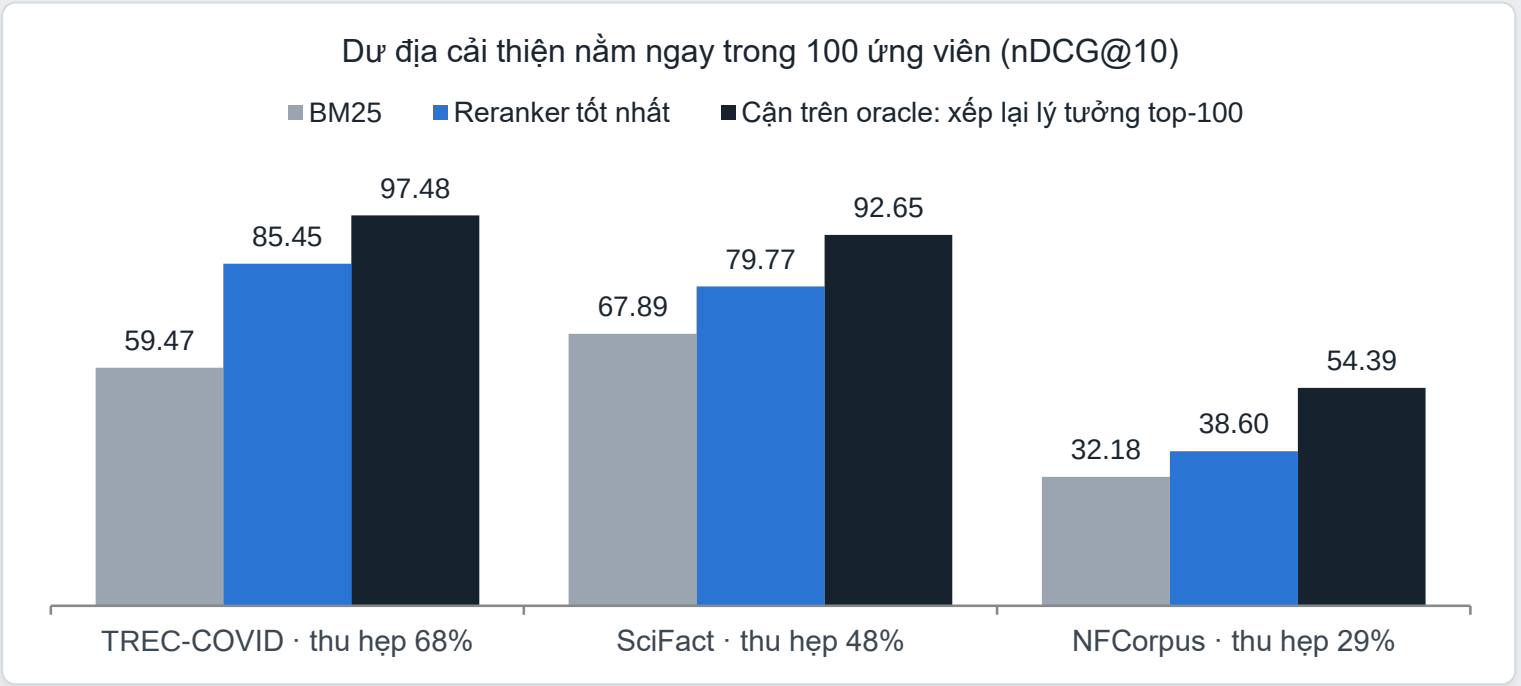
Nguồn: BM25 đo 11/11 bằng Pyserini, index beir-v1.0.0-trec-covid.flat, 50 truy vấn (phụ lục A12); độ trễ rerank 100 tài liệu và chi phí: report/tables/e4_cost.md (p50), ngoại suy × 1.713.

Tầng một tối ưu recall, nhưng RAG chỉ dùng vài tài liệu đầu

Khớp từ vựng, không khớp ngữ nghĩa (BM25).

Mã hóa tài liệu độc lập với truy vấn. Bi-encoder nén mỗi tài liệu thành một vector cố định, mất tương tác truy vấn–tài liệu ở mức token.

Mục tiêu tối ưu khác: tầng một tối ưu Recall@k, không tối ưu thứ hạng trong top-10.



Cận trên oracle = nDCG@10 khi xếp lại lý tưởng 100 ứng viên BM25 theo qrels (tài liệu chưa đánh giá tính 0). NFCorpus: 70/323 truy vấn không có tài liệu liên quan nào trong 100 ứng viên.

Ví dụ · topic 6: “rapid testing for Covid-19”

✗ BM25 hạng 1: “Coronavirus disease 2019 in children…”

✓ Sau rerank: “Types of Assays for SARS-CoV-2 Testing: A Review”

Trong RAG, LLM chỉ nhận top-k tài liệu. Ngữ cảnh dài tốn token; LLM khai thác thông tin ở giữa ngữ cảnh kém hơn ở hai đầu (Liu et al., Lost in the Middle, TACL 2024). → **Thứ hạng quan trọng**, không chỉ recall.

Nguồn: cận trên oracle tính 11/11 từ results/runs/<bộ>/test/bm25.trec và qrels (A11); reranker tốt nhất: report/tables/e1_main.md; topic 6: report/tables/error_cases.md; Liu et al. 2024.

Ba chiến lược suy luận: pointwise, pairwise, listwise

POINTWISE

chấm từng tài liệu



MỖI LẦN XEM
Một cặp (q, d)

ĐẦU RA
Điểm s(q, d), rồi sắp giảm dần

VÍ DỤ A / B / C
A: 0,95; B: 0,20; C: 0,80

→ A > C > B

VỚI 100 ỨNG VIÊN

100 cặp cần chấm; có thể batch

HẠN CHẾ
Cần thang điểm nhất quán

PAIRWISE · SETWISE

so cặp / nhóm nhỏ



MỖI LẦN XEM
Hai tài liệu; setwise: nhóm nhỏ

ĐẦU RA
Chọn tài liệu liên quan hơn

VÍ DỤ A / B / C
A thắng B; A thắng C; C thắng B

→ A > C > B

VỚI 100 ỨNG VIÊN

4.950 cặp; hỏi hai chiều: 9.900 đánh giá

HẠN CHẾ
Có thể A > B > C > A

LISTWISE

xếp cả danh sách



MỖI LẦN XEM
Một nhóm tài liệu cùng ngữ cảnh

ĐẦU RA
Hoán vị hoặc điểm theo ngữ cảnh

VÍ DỤ A / B / C
[q, A, B, C] → [A, C, B]

VỚI 100 ỨNG VIÊN

RankGPT 20/10: 9 cửa sổ nối tiếp

HẠN CHẾ
Ngữ cảnh dài; nhạy thứ tự đầu vào

Ví dụ giả lập: q = tác động của nhiệt lên pin; A: trả lời trực tiếp; B: tiết kiệm pin; C: lão hóa pin. Số đánh giá ≠ số request. Nguồn: RankGPT; PRP; Setwise.

Huấn luyện: ba họ hàm mất mát learning-to-rank

Họ	Hàm mất mát	Ý nghĩa
Pointwise	$\mathcal{L} = -[y \log \sigma(s) + (1-y)\log(1-\sigma(s))]$	Phân loại nhị phân liên quan / không liên quan (monoBERT, MonoT5)
Pairwise (RankNet, 2005)	$\mathcal{L} = \log(1 + e^{-(s_i - s_j)}), \quad d_i \succ d_j$	Tài liệu liên quan phải có điểm cao hơn tài liệu không liên quan
Listwise (softmax, kiểu ListNet 2007)	$\mathcal{L} = -\log \frac{e^{s(d^+)}}{e^{s(d^+)} + \sum_{k=1}^{n} e^{s(d_k^-)}}$	Trong một nhóm ứng viên, positive phải có điểm cao nhất so với mọi negative
LambdaRank / LambdaMART	$\lambda_{ij} = \frac{\partial \mathcal{L}_{\text{RankNet}}}{\partial s_i} \cdot \lvert \Delta \text{nDCG}_{ij} \rvert$	Gradient nhân trọng số |ΔnDCG|: lỗi ở top-10 bị phạt nặng, lỗi ở hạng 90 gần như không

Hàm mất mát huấn luyện ≠ chiến lược suy luận

LambdaMART huấn luyện bằng LambdaRank, BiLSTM-ESIM bằng softmax trên nhóm 1 positive + 7 negative, nhưng cả hai đều **suy luận pointwise**.

Không huấn luyện riêng cho rerank (zero-shot)

RankGPT (prompt), Jev (tiêu chí bằng ngôn ngữ tự nhiên).

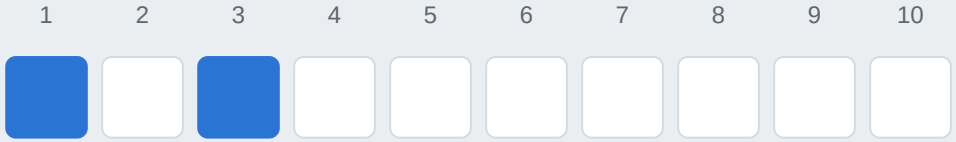
Nguồn: Burges et al. 2005 (RankNet); Cao et al. 2007 (ListNet); Burges 2010 (LambdaMART); src/rerank/lambdamart.py; src/kaggle_tasks/bilstm.py.

nDCG@10: độ đo có chiết khấu theo thứ hạng

$$\mathrm{DCG@10} = \sum_{i=1}^{10} \frac{\mathrm{rel}_i}{\log_2(i+1)} \qquad \mathrm{nDCG@10} = \frac{\mathrm{DCG@10}}{\mathrm{IDCG@10}}$$

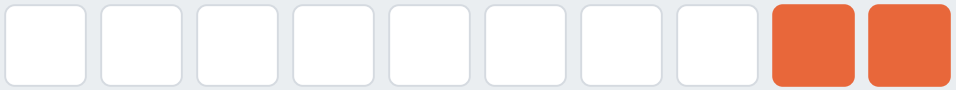
Gain tuyến tính (như BEIR, trec_eval); IDCG@10 là DCG@10 của thứ tự lý tưởng.

Ví dụ: truy vấn có 2 tài liệu liên quan (rel = 1)



nDCG ≈ **0,92**

hạng 1 và 3: DCG = 1 + 1/2 = 1,5; IDCG ≈ 1,63



nDCG ≈ **0,36**

hạng 9 và 10: DCG ≈ 0,59

Độ đo nhạy với **thứ hạng**, đúng mục tiêu tối ưu của reranker.

Giao thức đánh giá

Các run của nhóm dùng chung BM25 top-100 và “tiêu đề. abstract”. So sánh nội bộ có kiểm soát.

Số công bố dùng để tham khảo: BM25 NFCorpus và định dạng đầu vào chưa khớp hoàn toàn (slide 9).

Kiểm định ý nghĩa thống kê

Paired bootstrap 10.000 lần + Holm. p > 0,05: chưa thấy khác biệt; chưa chứng minh tương đương. Phạm vi hiệu chỉnh phải được ghi rõ.

Nguồn: src/eval/ir_metrics.py; Abdallah et al. 2025, arXiv:2508.16757.

Hai nguồn sai lệch khi đánh giá reranker

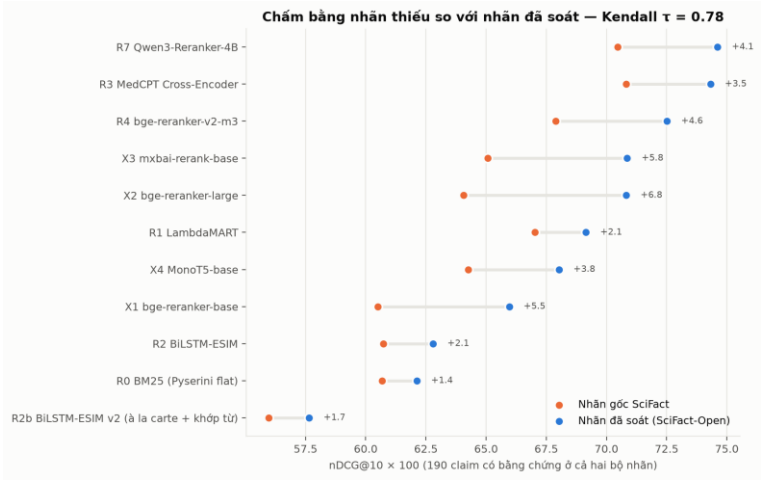
NGUỒN 1 Định dạng đầu vào không thống nhất

BM25 khớp TREC-COVID (59,47) và SciFact (67,89).
NFCorpus: nhóm 32,18; công bố 30,75.
bge-v2-m3 trên TREC-COVID:

Định dạng đầu vào	nDCG@10
Tiêu đề + abstract	**78,57**
Chỉ abstract	74,26
Số công bố trong bài báo	74,79

Cách nhập làm đổi 4,31 điểm. Các dòng công bố có thể khác định dạng; cần kiểm tra từng cấu hình trước khi so trực tiếp.

NGUỒN 2 Nhãn không đầy đủ (incomplete judgments)



JUDGED@10 CỦA BM25

91%
TREC-COVID

30%
NFCorpus

8,8%
SciFact

- SciFact-Open: chuyên gia chú giải bổ sung, số cặp (claim, bằng chứng) **209 → 460**. Đánh giá lại: cross-encoder **+3,5 đến +6,8**, BM25 chỉ +1,4.
- **Qwen3 và MedCPT hoán đổi hạng 1**; **6 cặp hệ thống đảo thứ hạng** (Kendall τ = 0,78, 11 hệ thống).
- TREC-COVID chỉ dùng qrels vòng 1: τ = 0,56, **17 cặp đảo thứ hạng** (13 hệ thống).

Nguồn: report/tables/e0_reproduction.md; report/tables/e3_labels.md; results/data_report/corpus_stats.json; hình report/figures/fig_e3_scifact_open.png.

Ba bộ dữ liệu, ba dạng truy vấn, ba nguồn nhãn

TREC-COVID

DẠNG TRUY VẤN

Câu hỏi ngôn ngữ tự nhiên

50 truy vấn

171.331 tài liệu trong kho

Độ dài truy vấn: 10,6 từ (TB)

Tài liệu liên quan / truy vấn: 493,5

Mức nhãn: 0 / 1 / 2

Tập huấn luyện: không có

Nguồn nhãn: NIST, 5 vòng chấm

BM25 Recall@100: 0,109

NFCorpus

DẠNG TRUY VẤN

Từ khóa (trung vị 2 từ)

323 truy vấn

3.633 tài liệu trong kho

Độ dài truy vấn: 3,3 từ (trung vị 2)

Tài liệu liên quan / truy vấn: 38,2

Mức nhãn: 1 / 2

Tập huấn luyện: 2.586 truy vấn

Nguồn nhãn: tự động từ hyperlink

BM25 Recall@100: 0,246

SciFact

DẠNG TRUY VẤN

Mệnh đề khoa học (claim)

300 truy vấn

5.183 tài liệu trong kho

Độ dài truy vấn: 12,6 từ (TB)

Tài liệu liên quan / truy vấn: 1,1

Mức nhãn: nhị phân

Tập huấn luyện: 632 claim

Nguồn nhãn: chuyên gia chú giải

BM25 Recall@100: 0,925

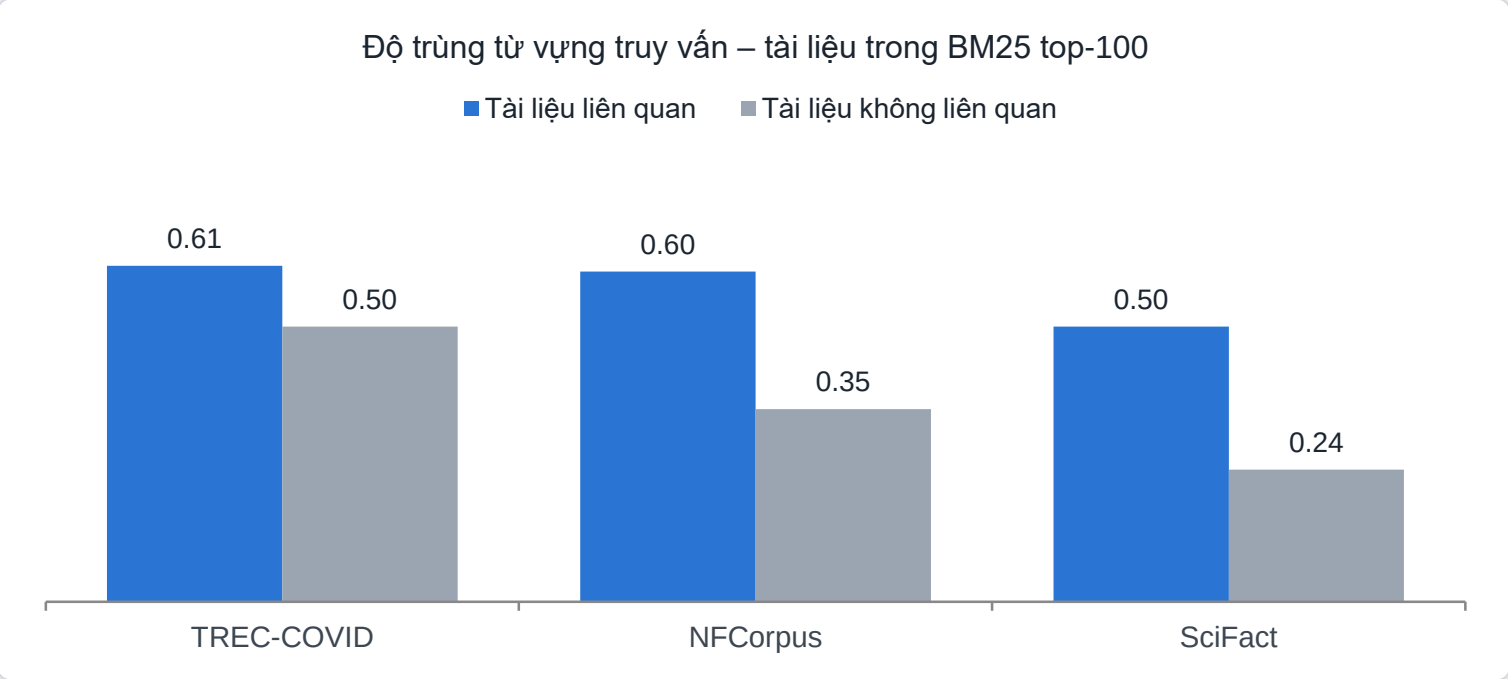
Nguồn: results/data_report/corpus_stats.json, splits.json; Thakur et al. 2021 (BEIR).

Ba phát hiện từ ngữ liệu

1. **Từ vựng trùng khớp phân biệt kém trên TREC-COVID.** Tỷ lệ từ truy vấn có trong tài liệu liên quan / không liên quan: 0,61 / 0,50, so với 0,60 / 0,35 (NFCorpus) và 0,50 / 0,24 (SciFact).

2. **Số tài liệu liên quan chênh hơn 400 lần.** 493,5 / 38,2 / 1,1 mỗi truy vấn. BM25 Recall@100 trên TREC-COVID chỉ 0,109, nhưng top-100 vẫn đủ tài liệu đúng cho top-10 (cận trên 97,48).

3. **Bẫy dữ liệu.** 24,6% tài liệu TREC-COVID không có abstract; 78% truy vấn TREC-COVID chứa từ OOV với BioWordVec; 70/323 truy vấn NFCorpus không có tài liệu liên quan trong top-100.



Độ trùng = tỷ lệ từ của truy vấn xuất hiện trong tài liệu, trung bình trên các tài liệu liên quan (xanh) và không liên quan (xám) trong 100 ứng viên BM25. Chênh lệch nhỏ → khớp từ khó tách tài liệu đúng.

Ví dụ bẫy · SciFact: hai claim gần trùng nhưng ngược nghĩa (TF-IDF cosine 0,90)
train: "…ND3 and ND6 **prevents** TDP-43-induced neuronal loss."
test: "…ND3 and ND6 **leads to increased** TDP-43-induced neuronal loss."

Ba bộ kiểm tra ba năng lực khác nhau: hiểu ngữ nghĩa khi từ vựng trùng nhiều (TREC-COVID), xử lý truy vấn rất ngắn (NFCorpus), suy luận trên mệnh đề khoa học (SciFact).

Nguồn: results/data_report/corpus_stats.json, bilstm_oov.json, splits.json; report/figures/fig_data_lexical_overlap.png; cận trên oracle: phụ lục A11.

Đặc điểm ngữ liệu quyết định thiết kế thí nghiệm

Quan sát	Quyết định thí nghiệm
Thiếu abstract: 24,6% TREC-COVID	Dùng “tiêu đề. abstract” cho mọi run của nhóm
TREC-COVID không có train	Học trên NFCorpus + SciFact; kiểm tra chuyển miền
Train–test có claim gần trùng	Loại 19 truy vấn train; chọn siêu tham số trên dev
Nhãn thưa; ứng viên có thể thiếu bài đúng	Báo Judged@10 + oracle; kiểm tra bằng nhãn bổ sung

Nguyên tắc đánh giá
Không chấm tay hoặc dùng LLM làm người chấm.
So sánh nội bộ: cùng ứng viên, đầu vào và nhãn.
Số công bố: đối chiếu kèm khác biệt giao thức.

Chia tập: train / dev / test
NFCorpus: 2.586 / 324 / 323
SciFact: 632 / 162 / 300
TREC-COVID: test 50

Nguồn: results/data_report/splits.json, corpus_stats.json, bilstm_oov.json; report/tables/e0_reproduction.md; NLP_PROJECT_PLAN.md mục 4.

Pointwise: chấm điểm độc lập từng tài liệu

Mô hình	Nguyên lý chấm điểm	TB 3 bộ	Độ trễ / q
BM25 (chưa rerank)	Khớp từ qua chỉ mục	53,18	—
LambdaMART	Trộn 11 đặc trưng bằng cây	61,00	+ tính đặc trưng
BiLSTM-ESIM	Mã hóa + soft alignment	51,38	0,06 s
bge-v2-m3	Cross-encoder → điểm	62,08	2,3 s
MonoT5-base	Xác suất token “true”	60,79	4,3 s
MedCPT-CE	Cross-encoder y sinh	61,02	0,64 s
Qwen3-Reranker-4B	Logit yes − logit no	67,24	25,0 s

BA ĐIỀU RÚT RA

1 Neural chưa chắc tốt hơn

BiLSTM: 51,38 < BM25: 53,18. Mô hình tiền huấn luyện đạt 57–67; chưa tách riêng tác động của tiền huấn luyện.

2 Nhạy với dạng truy vấn

MedCPT: đổi câu hỏi sang từ khóa NIST, TREC-COVID tăng 68,79 → 75,43. Topic 26: 3 → 40.

3 Batch và độ trễ

100 cặp cần chấm có thể gom batch. Với cấu hình T4 đã đo: Qwen3 25,0 s; bge-v2-m3 2,3 s.

Nguồn: report/tables/e1_main.md, e2_metadata.md, e4_cost.md; results/e1/e1_per_query.json. Chi tiết từng phương pháp: phụ lục.

POINTWISE

BiLSTM-ESIM: mã hóa, đối chiếu và chấm điểm

Đầu vào: câu hỏi q và tài liệu d. Mỗi từ được biểu diễn bằng BioWordVec 200 chiều (đóng băng).

1 BiLSTM: đọc q và d theo hai chiều
2 Soft alignment: đối chiếu từng token
3 So sánh: ghép, lấy hiệu và tích vector
4 BiLSTM + pooling → MLP → điểm

Huấn luyện: mỗi nhóm gồm 1 positive + 7 negative từ BM25; softmax loss, chọn checkpoint trên dev, 3 seed.
Suy luận: chấm độc lập từng cặp (q, d).

TREC-COVID	NFCorpus	SciFact	TB 3 bộ
55,38	26,44	72,30	51,38

Thấp hơn mốc chưa rerank (53,18). Chỉ cải thiện trên SciFact.

Những yếu tố có thể gây khó

78%	≈2 từ	≈3.200
truy vấn TREC-COVID chứa từ OOV	độ dài trung vị truy vấn NFCorpus	truy vấn huấn luyện

OOV, truy vấn ngắn và ít dữ liệu có thể góp phần. Chưa có ablation để tách riêng từng nguyên nhân.

TOPIC 26
nDCG@10 (0–100) · chưa rerank: 55

LambdaMART	BiLSTM-ESIM	bge-v2-m3	MedCPT	MonoT5	Qwen3	GPT-6 Luna	Jev
51	37	100	3 (kw 40)	86	100	56	47

Nguồn: report/tables/e1_main.md; report/tables/improvements.md; results/data_report/bilstm_oov.json; Chen et al., ACL 2017.

PAIRWISE · SETWISE

Pairwise và setwise: so sánh tương đối giữa các ứng viên

PRP-ALLPAIR

So mọi cặp, hỏi hai chiều

4.950

cặp không thứ tự, k = 100

Hai chiều: 9.900 đánh giá. Số request tùy batch.

PRP-SORTING

Sắp xếp bằng phép so cặp (heap sort)

O(k log k)

lượt so sánh

Ít lượt hơn all-pairs, nhưng phải chạy tuần tự.

PRP-SLIDING-K

K lượt nổi bọt để lấy top-K

O(K·k)

lượt so sánh, K = 10

Chỉ cần đúng ở top-K.

SETWISE (2024)

Chọn tài liệu tốt nhất trong nhóm c tài liệu

62,27

TB nDCG@10 · Flan-T5-XXL (công bố)

Mỗi lượt so c tài liệu → ít lượt LLM hơn pairwise.

Đặc điểm của cách tiếp cận

1. **Ưu điểm:** chỉ cần so sánh tương đối “A hay B liên quan hơn”, không cần thang điểm tuyệt đối.

2. **Hạn chế:** chi phí tăng nhanh theo k; kết quả so cặp có thể không bắc cầu (A ≻ B ≻ C ≻ A); nhạy với thứ tự A, B trong prompt.

3. **Nhóm chưa chạy pairwise/setwise; số bên trên là công bố. Chế độ pointwise/listwise của Jev là hướng kiểm tra thêm.**

Nguồn: Qin et al. 2023 (PRP: Allpair, Sorting, Sliding-K); Zhuang et al. 2024 (Setwise); Abdallah et al. 2025 (bảng 3).

LISTWISE

Listwise: LLM sinh trực tiếp hoán vị bằng cửa sổ trượt

- **Listwise (RankGPT, 2023):** đưa LLM một cửa sổ w ứng viên đã đánh số; LLM sinh trực tiếp hoán vị "[3] > [1] > …". Danh sách dài hơn cửa sổ thì trượt từ cuối danh sách lên, để tài liệu tốt "nổi" dần lên đầu.

```
for (i, j) in (80,100), (70,90), …, (0,20):
    π ← LLM(q, d[i:j])      # hoán vị 20 ứng viên
    d[i:j] ← π(d[i:j])      # top-10 đi tiếp lượt sau
# k=100, w=20, s=10 → (k − w)/s + 1 = 9 lượt tuần tự
```

Biến thể: RankGPT zero-shot (chỉ prompt); RankZephyr 7B (LLM mã nguồn mở); ListT5 (xếp theo nhóm nhỏ, tournament sort).

Cài đặt của nhóm (GPT-6 Luna): prompt hoán vị của RankGPT, đoạn văn cắt 300 từ, đầu ra JSON (structured outputs); ID thiếu nối vào cuối, ID trùng bị loại.

Model	Suy luận	TB	Nguồn
RankGPT gpt-3.5	listwise	60,91	công bố
RankZephyr 7B	listwise	64,14	công bố
RankGPT gpt-4 (chỉ top-30)	listwise	66,31	công bố
ListT5-3B	listwise	66,47	công bố
GPT-6 Luna	**listwise**	**67,94**	**nhóm**

GPT-6 Luna: 85,45 / 38,60 / 79,77, cao nhất bảng.

29 s
/truy vấn (9 lượt tuần tự)

5,61 USD
/1.000 truy vấn

56
Topic 26 (≈ chưa rerank)

TOPIC 26
nDCG@10 (0–100) · chưa rerank: 55

LambdaMART	BiLSTM-ESIM	bge-v2-m3	MedCPT	MonoT5	Qwen3	GPT-6 Luna	Jev
51	37	100	3 (kw 40)	86	100	56	?

Nguồn: report/tables/e1_main.md, e4_cost.md; results/e1/luna_run_summary.json; Sun et al. 2023 (RankGPT); Pradeep et al. 2023 (RankZephyr); Yoon et al. 2024 (ListT5); Abdallah et al. 2025.

Jev (2026): ra quyết định trực tiếp, không sinh văn bản

Jev của TypeSafe AI, công bố 15/09/2026. TypeSafe gọi đây là **"System One model"**, theo khái niệm tư duy nhanh (System 1) của Kahneman.

Cách dùng API: nhiều tài liệu chung ngữ cảnh; trả điểm liên quan từng tài liệu để sắp xếp. Thư viện chia lô khi quá dài; không suy ra số forward pass nội bộ.

```
state     = { query, documents: { doc_0 … doc_n } }
questions = { doc_i: Noul("Is documents.doc_i
                relevant to query?",
                true: "…", false: "…") }
answers   = Jev(state, questions)  # mỗi lô
score_i   = P(true) → sắp xếp giảm dần
```

Mô hình hộp đen: không công bố kiến trúc, số tham số, dữ liệu huấn luyện.

	RankGPT / Luna	Qwen3	Jev
Ngữ cảnh mỗi lượt	20 tài liệu / lượt	1 tài liệu	**Nhóm tài liệu**
Đầu ra	Chuỗi hoán vị (cần parse)	logit yes − no	**P(true) từng tài liệu**
Đơn vị xử lý	9 cửa sổ	100 cặp; batch	**TB 1,8 request / q**
Tiêu chí	Prompt	Instruction cố định	**Tiêu chí ngôn ngữ tự nhiên, không cần huấn luyện lại**

Theo TypeSafe: RLCD hướng tới xác suất được hiệu chỉnh. Nhóm chưa kiểm tra calibration trên dữ liệu y sinh. Log thực nghiệm: TB 1,8 request/truy vấn; p50 1,08 s.

TOPIC 26
nDCG@10 (0–100) · chưa rerank: 55

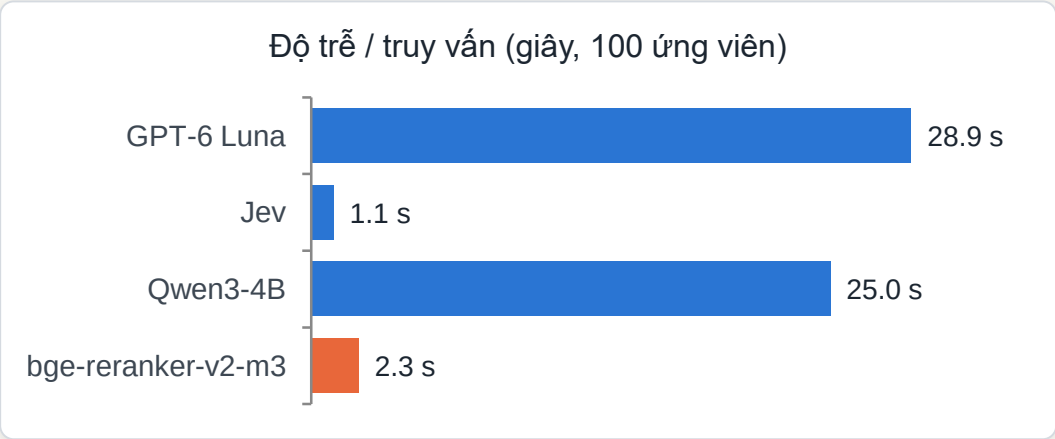
LambdaMART	BiLSTM-ESIM	bge-v2-m3	MedCPT	MonoT5	Qwen3	GPT-6 Luna	Jev
51	37	100	3 (kw 40)	86	100	56	?

Nguồn: docs.typesafe.ai/concepts/system-one; typesafe.ai/blog/introducing-system-one-models-and-jev; thư viện jev-reranker 0.1.2 (src/rerank/jev.py).

Điểm số gần nhau, độ trễ khác đáng kể

Model	Suy luận	TREC-COVID	NFCorpus	SciFact	TB	Độ trễ/truy vấn	USD / 1.000 truy vấn
GPT-6 Luna	listwise, 9 lượt	85,45	38,60	79,77	67,94	28,9 s	5,61
Jev	**theo nhóm**	**84,41**	**38,24**	**79,14**	**67,27**	**1,1 s**	**1,62**
Qwen3-4B	pointwise	85,00	37,37	79,35	67,24	25,0 s	2,48*
bge-reranker-v2-m3	pointwise	78,57	33,69	73,99	62,08	2,3 s	0,22*

* mô hình chạy local: USD quy đổi theo giá thuê GPU T4 (ước lượng); API: chi phí thực tế từ log.



- **Ba mô hình đầu: phần lớn so sánh chưa thấy khác biệt. Holm cho 3 cặp / bộ: Luna > Qwen3 trên NFCorpus (p = 0,0324). Nếu gộp 9 phép thử: p = 0,0972.**
- Jev > bge-v2-m3 trên NFCorpus và SciFact; TREC-COVID chưa có ý nghĩa thống kê.
- Jev: 673 truy vấn, 1.243 request (TB 1,8 / q), tổng 1,09 USD.
- Đây là so sánh hệ thống; chưa tách được tác động riêng của chiến lược suy luận.

TOPIC 26
nDCG@10 (0–100) · chưa rerank: 55

LambdaMART	BiLSTM-ESIM	bge-v2-m3	MedCPT	MonoT5	Qwen3	GPT-6 Luna	Jev
51	**37**	**100**	**3 (kw 40)**	**86**	**100**	**56**	**47**

Nguồn: report/tables/e1_main.md; report/tables/e4_cost.md; results/api_logs/jev__*.jsonl; kiểm định bằng src/eval/significance.py trên results/e1/e1_per_query.json.

Tiến bộ không đơn điệu theo thời gian

Mô hình	TREC	NF	SciFact	TB
BM25	59,47	32,18	67,89	53,18
BiLSTM	55,38	26,44	72,30	51,38
LambdaMART	71,37	35,67	75,97	61,00
MedCPT	68,79	34,68	79,58	61,02
bge-v2-m3	78,57	33,69	73,99	62,08
Qwen3-4B	85,00	37,37	79,35	67,24
Jev	84,41	38,24	79,14	67,27
GPT-6 Luna	85,45	38,60	79,77	67,94

Chỉ các run của nhóm · nDCG@10 × 100 · Bảng đầy đủ: phụ lục

1 **Mới hơn chưa chắc tốt hơn. BiLSTM thấp hơn LambdaMART và BM25. Đây là quan sát giữa các hệ thống, chưa là ablation về kiến trúc hay tiền huấn luyện.**

2 **Chuyên ngành chưa chắc tốt hơn. MedCPT nhạy với dạng truy vấn: từ khóa giúp trên TREC-COVID. Chưa tách riêng tác động của dữ liệu huấn luyện.**

3 **Chưa kết luận listwise hơn pointwise. Các hệ thống dẫn đầu có điểm gần nhau nhưng khác độ trễ; cần cố định mô hình rồi đổi chiến lược.**

Giới hạn: dữ liệu BEIR công khai lâu năm; chưa loại trừ nhiễm dữ liệu tiền huấn luyện. Cần truy vấn mới và thí nghiệm có kiểm soát.

Nguồn: report/tables/e1_main.md; e2_metadata.md; e4_cost.md; Abdallah et al. 2025. NF = NFCorpus.

KẾT LUẬN

Ba kết luận chính

1

Reranking tồn tại do đánh đổi chi phí và chất lượng

Rerank 100 ứng viên thu hẹp 68% khoảng cách BM25–oracle trên TREC-COVID (Luna). Reranker chỉ đổi thứ tự; không bổ sung tài liệu bị tầng một bỏ sót.

2

Điểm số gần nhau, chi phí khác nhau

Luna, Jev và Qwen3 đạt TB 67,24–67,94; p50 khoảng 1–29 s trong cấu hình đã đo. Chưa chứng minh tương đương hoặc tác động riêng của pointwise/listwise.

3

So sánh reranker cần cùng giao thức đánh giá

So sánh nội bộ: cùng ứng viên, đầu vào và nhãn. Cách nhập đổi 4,31 điểm; nhãn bổ sung đảo 6 cặp hệ thống. Số công bố cần đối chiếu sai khác giao thức.

Cảm ơn thầy cô và các bạn · Hỏi đáp

BM25: bộ truy xuất tầng một và mốc chưa rerank

Nguyên lý: mô hình xác suất (Probabilistic Relevance Framework) trên biểu diễn bag-of-words: điểm là tổng đóng góp của các từ truy vấn xuất hiện trong tài liệu.

$$s(q,d) = \sum_{t \in q} \mathrm{IDF}(t) \cdot \frac{\mathrm{tf}(t,d)\,(k_1+1)}{\mathrm{tf}(t,d) + k_1\left(1 - b + b\,\frac{|d|}{\mathrm{avgdl}}\right)}$$

$$\mathrm{IDF}(t) = \ln\left(1 + \frac{N - \mathrm{df}(t) + 0{,}5}{\mathrm{df}(t) + 0{,}5}\right)$$

- tf(t,d): tần suất của t trong d; |d|/avgdl: độ dài tương đối của d.
- df(t): số tài liệu chứa t trong kho N tài liệu; từ hiếm có IDF cao.
- k_1 = 0,9: bão hòa TF; b = 0,4: chuẩn hóa độ dài (mặc định Pyserini).

Huấn luyện
Không huấn luyện; k_1, b cố định.

Chi phí suy luận
Duyệt posting list trên chỉ mục ngược: 16 ms/truy vấn trên toàn kho.

TREC-COVID	NFCorpus	SciFact	TB 3 bộ
59,47	32,18	67,89	53,18

Vai trò trong thí nghiệm

Là **bộ truy xuất tầng một** (tạo 100 ứng viên) và **mốc chưa rerank**; không phải reranker được so sánh. Nó quyết định cận trên oracle (slide 5).

Hạn chế: không nắm bắt ngữ nghĩa (lệch từ vựng); chỉ dùng một tín hiệu liên quan duy nhất.

Nguồn: report/tables/e1_main.md; Robertson et al., TREC-3 (1994).

POINTWISE

LambdaMART (2010): learning-to-rank trên đặc trưng thủ công

Nguyên lý: mô hình cộng tính gồm M cây hồi quy (gradient boosting, MART); mỗi cây khớp λ-gradient của LambdaRank: gradient RankNet nhân với |ΔnDCG| khi hoán đổi một cặp tài liệu.

11 đặc trưng φ(q, d): điểm và hạng BM25, TF-IDF cosine, độ tương đồng MedCPT bi-encoder (thô và chuẩn hóa z), độ trùng từ với truy vấn và với tiêu đề, độ dài tài liệu và truy vấn, có tiêu đề hay không.

Mô hình $$s(q,d) = F_M(\mathbf{x}) = \sum_{m=1}^{M} \eta\, h_m(\mathbf{x}), \quad \mathbf{x} = \phi(q,d) \in \mathbb{R}^{11}$$

λ-gradient $$\lambda_{ij} = \frac{-\sigma |\Delta \mathrm{nDCG}_{ij}|}{1 + e^{\sigma(s_i - s_j)}}, \quad \lambda_i = \sum_{j:\, y_i > y_j} \lambda_{ij} - \sum_{j:\, y_j > y_i} \lambda_{ji}$$

Huấn luyện: LightGBM lambdarank, tối đa M = 1.000 cây, η = 0,05, 31 lá/cây; early stopping theo nDCG@10 trên dev; dữ liệu NFCorpus + SciFact, 3 seed. Suy luận **pointwise**: mỗi tài liệu một lượt tính F(x).

TREC-COVID	NFCorpus	SciFact	TB 3 bộ
71,37	35,67	75,97	61,00

+8 điểm so với chưa rerank · cải thiện ở **33/50** truy vấn TREC-COVID.

68% feature importance (gain) thuộc về **đặc trưng MedCPT**, một mô hình neural.

Hạn chế: chất lượng bị chặn bởi feature engineering: mô hình chỉ tốt bằng các đặc trưng do con người thiết kế.

TOPIC 26
nDCG@10 (0–100) · chưa rerank: 55

LambdaMART	BiLSTM-ESIM	bge-v2-m3	MedCPT	MonoT5	Qwen3	GPT-6 Luna	Jev
51	37	100	3 (kw 40)	86	100	56	47

Nguồn: report/tables/e1_main.md; results/e1/lambdamart_train.json; report/tables/error_cases.md.

POINTWISE

Cross-encoder (2019 →): tiền huấn luyện và mã hóa chung

Bi-encoder: mã hóa độc lập

$$s(q,d) = E_Q(q)^\top E_D(d)$$

Hai encoder độc lập; embedding tài liệu tính trước (offline) → phù hợp **tầng một**.

Cross-encoder: mã hóa chung

$$\mathbf{h} = \mathrm{Enc}([\mathrm{CLS}]\ q\ [\mathrm{SEP}]\ d\ [\mathrm{SEP}])$$

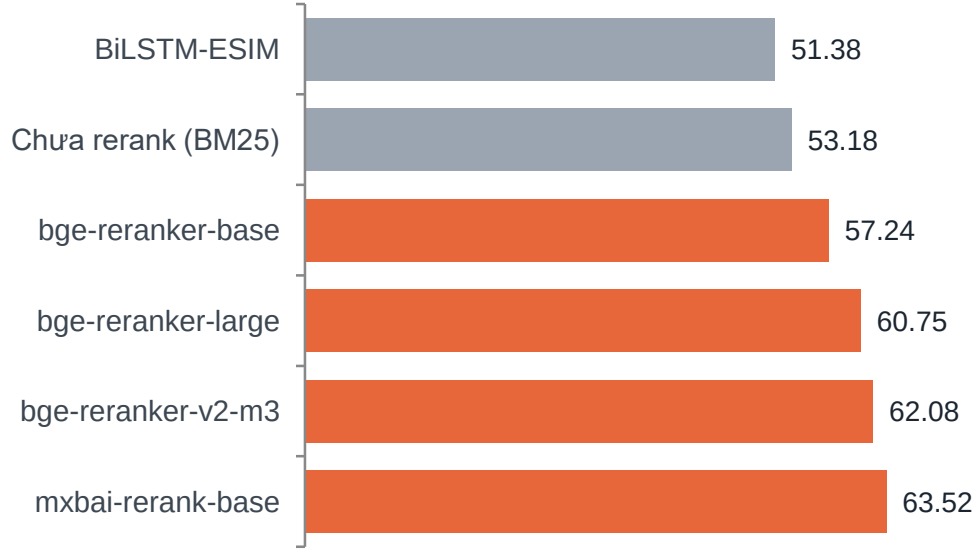
$$s(q,d) = \mathbf{w}^\top \mathbf{h}_{[\mathrm{CLS}]} + b$$

Self-attention giữa mọi token của q và d; một forward pass cho mỗi cặp → phù hợp **tầng hai**.

Huấn luyện: ① tiền huấn luyện tự giám sát trên văn bản không nhãn (BERT: masked language modeling); ② fine-tune trên các cặp (truy vấn, đoạn văn) có nhãn; monoBERT dùng cross-entropy pointwise trên MS MARCO.

Chi phí suy luận: 100 forward pass theo batch trên GPU, đầu vào cắt 512 token; self-attention O((|q| + |d|)²) cho mỗi cặp; 0,6–2,3 s/truy vấn.

nDCG@10 TB 3 bộ (zero-shot, không fine-tune)



bge-v2-m3 cải thiện so với chưa rerank ở **40/50** truy vấn TREC-COVID. mxbai **base** vượt bge **large**: nhiều tham số hơn không đảm bảo chất lượng cao hơn.

TOPIC 26
nDCG@10 (0–100) · chưa rerank: 55

LambdaMART	BiLSTM-ESIM	bge-v2-m3	MedCPT	MonoT5	Qwen3	GPT-6 Luna	Jev
51	37	100	3 (kw 40)	86	100	56	47

Nguồn: report/tables/e1_main.md; report/tables/e4_cost.md; Nogueira & Cho 2019 (monoBERT).

MedCPT (2023): dữ liệu huấn luyện và lệch phân phối truy vấn

MedCPT-CE: cross-encoder nền PubMedBERT, **huấn luyện trên 255 triệu lượt click từ log tìm kiếm PubMed** (cặp truy vấn–bài báo; Jin et al., 2023).

TREC-COVID	NFCorpus	SciFact	TB 3 bộ
68,79	34,68	79,58	61,02

- SciFact 79,58: cao hơn các dòng công bố được chọn trong bảng đối chiếu.
- TREC-COVID 68,79: thấp hơn bge-v2-m3 (78,57).

Một giả thuyết cho topic 26: dạng truy vấn không khớp log PubMed. Thí nghiệm đổi cách nhập hỗ trợ giả thuyết, chưa chứng minh nguyên nhân duy nhất.

Cùng 100 ứng viên, chỉ thay đổi dạng truy vấn đầu vào

Câu hỏi tự nhiên (mặc định)

3

Topic 26

TREC-COVID: **68,79**

→

Truy vấn từ khóa (NIST)

40

Topic 26

TREC-COVID: **75,43** (+6,6)

Đổi sang từ khóa giúp MedCPT trên TREC-COVID. Kết quả cho thấy độ nhạy với cách diễn đạt; chưa tách được tác động của miền và dữ liệu huấn luyện.

TOPIC 26
nDCG@10 (0–100) · chưa rerank: 55

LambdaMART	BiLSTM-ESIM	bge-v2-m3	MedCPT	MonoT5	Qwen3	GPT-6 Luna	Jev
51	37	100	3 (kw 40)	86	100	56	47

Nguồn: report/tables/e1_main.md; report/tables/e2_metadata.md; Jin et al. 2023 (MedCPT).

MonoT5 và Qwen3: rerank bằng xác suất sinh token

MonoT5 (2020)

Quy rerank về bài toán sinh một token nhị phân (seq2seq).

```
Đầu vào: "Query: q  Document: d  Relevant:"
```

$$s(q,d) = \log \frac{e^{z_{\text{true}}}}{e^{z_{\text{true}}} + e^{z_{\text{false}}}}$$

Huấn luyện: fine-tune T5 (seq2seq) trên MS MARCO để sinh token “true” / “false”; z là logit ở bước giải mã đầu tiên.

TREC-COVID	NFCorpus	SciFact	TB 3 bộ
74,08	35,06	73,24	60,79

Topic 26: **86**

Qwen3-Reranker-4B (2025)

Cùng nguyên lý, với LLM decoder-only 4 tỉ tham số.

```
"Judge whether the Document meets the
 requirements… answer only yes or no"
```

$$s(q,d) = z_{\text{yes}} - z_{\text{no}} = \log \frac{P(\text{yes})}{P(\text{no})}$$

Suy luận: đọc logit yes/no ở cuối prompt; nhóm không fine-tune thêm. Chấm 100 cặp theo batch: ≈25 s/truy vấn trên GPU T4.

TREC-COVID	NFCorpus	SciFact	TB 3 bộ
85,00	37,37	79,35	67,24

Cải thiện so với chưa rerank ở **44/50** truy vấn · Topic 26: **100**

Hạn chế: cả hai vẫn suy luận pointwise. Nếu LLM xét nhiều ứng viên trong cùng một ngữ cảnh thì sao?

TOPIC 26
nDCG@10 (0–100) · chưa rerank: 55

LambdaMART	BiLSTM-ESIM	bge-v2-m3	MedCPT	MonoT5	Qwen3	GPT-6 Luna	Jev
51	37	100	3 (kw 40)	86	100	56	47

Nguồn: report/tables/e1_main.md; report/tables/e4_cost.md; Nogueira et al. 2020; model card Qwen3-Reranker.

Bảng kết quả đầy đủ (nDCG@10 × 100)

Model	TREC-COVID	NFCorpus	SciFact	TB	Nguồn
Chưa rerank (BM25 top-100)	59,47	32,18	67,89	53,18	nhóm
Cận trên oracle (top-100)	**97,48**	**54,39**	**92,65**	**—**	**nhóm, tính 11/11**
LambdaMART	71,37	35,67	75,97	61,00	nhóm (3 seed)
BiLSTM-ESIM	55,38	26,44	72,30	51,38	nhóm (3 seed)
BiLSTM-ESIM v2	56,54	26,73	70,15	51,14	nhóm (3 seed)
MedCPT-CE	68,79	34,68	79,58	61,02	nhóm
bge-reranker-base	68,61	31,55	71,55	57,24	nhóm
bge-reranker-large	74,23	33,83	74,20	60,75	nhóm
bge-reranker-v2-m3	78,57	33,69	73,99	62,08	nhóm
mxbai-rerank-base	83,06	35,48	72,03	63,52	nhóm
MonoT5-base	74,08	35,06	73,24	60,79	nhóm
Qwen3-Reranker-4B	85,00	37,37	79,35	67,24	nhóm
GPT-6 Luna (listwise)	85,45	38,60	79,77	67,94	nhóm (đồng đội chạy)
Jev (listwise)	84,41	38,24	79,14	67,27	nhóm

Model	TREC-COVID	NFCorpus	SciFact	TB	Nguồn
monoBERT	70,01	36,88	71,36	59,42	công bố
MonoT5-3B	80,71	38,97	76,57	65,42	công bố
InRanker-3B	81,75	38,25	78,31	66,10	công bố
Cohere Rerank-v2	81,81	36,36	74,44	64,20	công bố
RankGPT gpt-3.5	76,67	35,62	70,43	60,91	công bố
RankGPT gpt-4 (top-30)	85,51	38,47	74,95	66,31	công bố
RankZephyr 7B	80,70	36,58	75,13	64,14	công bố
ListT5-3B	84,70	37,70	77,00	66,47	công bố
Setwise Flan-T5-XXL	76,8	34,6	75,4	62,27	công bố

Nguồn: report/tables/e1_main.md, e1_full.md; Abdallah et al. 2025.

Độ trễ, chi phí và thắng/thua so với chưa rerank

Độ trễ và chi phí (p50, rerank 100 ứng viên)

Model	Độ trễ (p50)	USD / 1.000 truy vấn
Tầng một BM25 (toàn kho)	16 ms	0
BiLSTM	0,06 s	0,006
MedCPT	0,64 s	0,06
Jev	1,08 s	1,62
mxbai	1,74 s	0,17
bge-v2-m3	2,28 s	0,22
MonoT5	4,32 s	0,42
Qwen3	25,0 s	2,48
Luna	28,9 s	5,61

Chi phí mô hình local là ước lượng theo giá thuê GPU T4; chi phí API là số thực tế từ log.

Thắng / thua so với chưa rerank trên 50 truy vấn TREC-COVID

Model	Thắng	Thua
Luna	45	3
Qwen3	44	3
mxbai	41	6
Jev	41	7
bge-v2-m3	40	7
MonoT5	34	14
LambdaMART	33	17
MedCPT	32	16
BiLSTM	19	31

Nguồn: report/tables/e4_cost.md; results/e1/e1_per_query.json.

Cách tính cận trên oracle và độ trễ BM25

A11 · Cận trên oracle của reranker

Với mỗi truy vấn, sắp xếp 100 ứng viên BM25 theo nhãn qrels (tài liệu chưa đánh giá = 0), rồi tính nDCG@10.

Kết quả: 97,48 / 54,39 / 92,65 (TREC-COVID / NFCorpus / SciFact).

Truy vấn không có tài liệu liên quan trong top-100: 0/50, 70/323 (gồm 15 truy vấn BM25 không trả về kết quả), 21/300.

Tính ngày 11/11 từ results/runs/<bộ>/test/bm25.trec và qrels.

A12 · Độ trễ BM25 và ngoại suy toàn kho

Pyserini, index beir-v1.0.0-trec-covid.flat, 50 truy vấn, 1 luồng, top-100.

p50: 16,4 ms · **tối đa:** 69,4 ms.

Ngoại suy toàn kho = p50 rerank 100 tài liệu × 1.713,31 (= 171.331 / 100). Ước lượng tuyến tính, chỉ để minh họa bậc độ lớn.

Đo ngày 11/11; report/tables/e4_cost.md.

Nguồn: hai số liệu tính riêng ngày 11/11, chưa nằm trong report/tables/.

Lựa chọn reranker khi triển khai: theo ngân sách độ trễ

GẦN NHƯ 0

Không rerank (tầng một)

53,18
TB nDCG@10

Mốc so sánh: thứ tự BM25.

< 1 GIÂY

MedCPT (0,64 s, GPU)

61,02
TB nDCG@10

Nhạy với dạng truy vấn.

1–2 GIÂY

Jev (1,1 s, API) hoặc mxbai (1,7 s, GPU)

67,27 / 63,52
TB nDCG@10

Điểm gần Luna / Qwen3.

XỬ LÝ OFFLINE (BATCH)

GPT-6 Luna, Qwen3

67,94 / 67,24
TB nDCG@10

25–29 s/truy vấn.

Ba tham số thiết kế khác

Độ sâu k: ứng viên nhiều hơn có thể tăng trần oracle. Chi phí phụ thuộc mô hình, cửa sổ và batching; không luôn tuyến tính.

Cascade nhiều tầng: cross-encoder cắt 100 ứng viên xuống 20, rồi LLM chỉ rerank top-20 (như RankGPT gpt-4 chỉ xếp top-30). Nhóm chưa đo.

Bảo mật dữ liệu: API (Luna, Jev) gửi văn bản ra bên thứ ba; mô hình local xử lý tại chỗ (on-premise).

Nguồn: report/tables/e4_cost.md; report/figures/fig_e4_pareto.png.

Câu hỏi nghiên cứu còn mở

1. **Cố định mô hình, thay đổi chiến lược suy luận.** Jev hỗ trợ cả listwise lẫn pointwise, cho phép một thí nghiệm có kiểm soát (ước tính khoảng 1,1 USD). Thí nghiệm này cũng giúp lý giải trường hợp topic 26.

2. **Nhãn không đầy đủ với LLM.** Đánh giá lại trên qrels bổ sung của SciFact-Open mới gồm 11 mô hình local, chưa có Luna và Jev.

3. **Nhiễm dữ liệu (data contamination).** Các bộ BEIR công khai từ 2021 nên LLM có thể đã gặp khi huấn luyện. Cần truy vấn mới để kiểm tra (Abdallah et al. 2025: FutureQueryEval).

4. **Tiêu chí liên quan theo từng topic.** Dùng mô tả “thế nào là liên quan” (narrative) của NIST làm tiêu chí cho Jev thay cho tiêu chí chung.

5. **Độ hiệu chỉnh (calibration) của xác suất Jev.** Đối chiếu với qrels bằng reliability diagram; không phát sinh thêm chi phí API.

Nguồn: report/tables/e3_labels.md; scripts/run_api.py --dry-run.