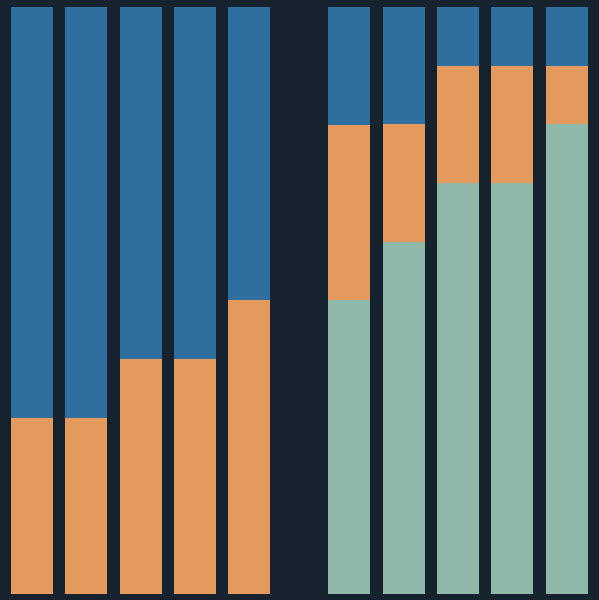
SEMINAR NLP · CS2308.11.CH

Mô hình hoá biến đổi nghĩa của từ qua nhiều thời kỳ

SemEval-2027 Task 3: phương pháp, thực nghiệm và so sánh kết quả

Nhóm 5
Đỗ Phi Sơn - 250101102
Nguyễn Ngọc Nam - 250101094
Lê Công Trí -250101109
Lê Đình Trí - 250101110



Minh hoạ: phân phối nghĩa của một từ qua 10 thời kỳ, có khoảng trống 1915–2006

1 · ĐẶT VẤN ĐỀ

Nghĩa của từ không đứng yên theo thời gian

fröken (tiếng Thụy Điển)

"Cô gái chưa chồng" → thêm nghĩa "người phụ nữ làm nghề": cô giáo, nhân viên cửa hàng, bưu điện

mouse (tiếng Anh)

"Con chuột" → thêm nghĩa "thiết bị điều khiển máy tính"

Vì sao vấn đề này đáng quan tâm

- Đọc đúng văn bản lịch sử: nhà nghiên cứu nhân văn cần biết một từ mang nghĩa gì ở từng giai đoạn
- Mô hình ngôn ngữ học từ văn bản hiện đại dễ hiểu sai văn bản cũ

1 · ĐẶT VẤN ĐỀ

Nhiệm vụ: từ hai thời kỳ sang nhiều thời kỳ

SemEval-2020 Task 1: 2 thời kỳ, mỗi từ một điểm thay đổi

→

SemEval-2027 Task 3: tối đa 10 thời kỳ, theo dõi từng nghĩa; 6 ngôn ngữ, 132 từ test

Nhiệm vụ	Đầu vào → đầu ra	Độ đo
1a. Gán nghĩa	Các câu chứa từ đích → mã cụm nghĩa cho mỗi câu	BCubed F1
1b. Động thái nghĩa	Dùng lại file của 1a → BTC tính JSD giữa 2 thời kỳ liền nhau	Spearman
2. Kiểm định giả thuyết	Câu + định nghĩa một nghĩa đích → 0/1	F1 trung bình theo từ

Điểm then chốt: 1a và 1b chấm trên cùng một file nộp, nên phân cụm vừa phải đúng, vừa phải phản ánh đúng sự thay đổi theo thời gian.

2 · KHẢO SÁT NGỮ LIỆU

Ngữ liệu dev: 10 từ tiếng Thụy Điển có nhãn

10
từ đích, mỗi từ 3–12 nghĩa gold

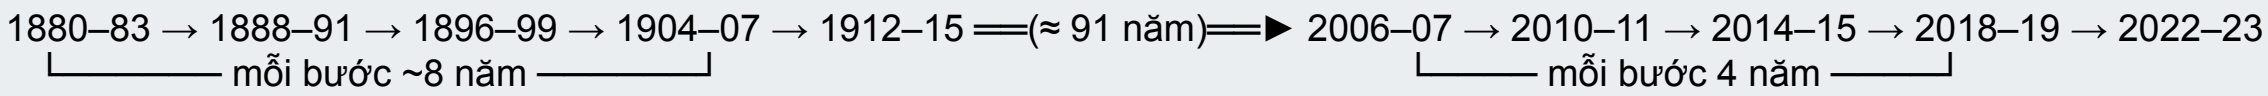
1983
câu, ~27 từ/câu

10
thời kỳ: 1880–1915 và 2006–2023

13%
câu mang hơn một nghĩa (262 câu)

Khoảng trống khoảng 90 năm
JSD gold ở cặp 1912 → 2006 trung bình 0.173, gấp 3 các cặp khác (0.058)

Phân phối nghĩa rất lệch
8/10 từ có nghĩa phổ biến nhất chiếm 73–95% số câu; riêng suga có 12 nghĩa



2 · KHẢO SÁT NGỮ LIỆU

Phân tích: ba phát hiện

1

Gộp mỗi từ thành 1 cụm đã được BCubed 0.756

Vì nghĩa phổ biến nhất chiếm đa số câu. Nhưng khi đó JSD = 0 ở mọi cặp thời kỳ, nên 1b không tính được.

2

Subtask 2 chính là một nghĩa gold của Subtask 1

Đúng với cả 10 từ, 1983 câu, không ngoại lệ. Đoán toàn 1 đã được F1 0.472 cho Subtask 2.

3

“Bẫy” dữ liệu

Lỗi OCR, chính tả cổ (sorn, öfver, hvilket); nhiều dạng biến tố (kvinna có 12 dạng); tên trường trong file khác mô tả đề.

2 · KHẢO SÁT NGỮ LIỆU

Ngữ liệu quyết định cách giải quyết

Quan sát từ ngữ liệu	Quyết định thiết kế
1 cụm/từ có 1a cao nhưng mất 1b	Tinh chỉnh theo trung bình (1a + 1b) / 2
Gán 1 nghĩa/câu đã đạt trần 0.966	Mỗi câu một nghĩa, bỏ qua gán đa nhãn
Câu cùng chủ đề vẫn có thể dùng từ theo nghĩa khác; OCR và biến tố gây nhiễu	Lấy embedding của riêng từ đích, bằng mô hình học so nghĩa từ (Word-in-Context)
Cụm 1–2 câu tạo sự thay đổi nghĩa giả	Gộp cụm nhỏ vào cụm lớn gần nhất
ST2 trùng một nghĩa gold của ST1	Thử làm mượt ST2 theo cụm ST1
Chỉ có 10 từ để tinh chỉnh	Chỉ tinh chỉnh 2 tham số: ngưỡng và kích thước cụm tối thiểu

3 · PHƯƠNG PHÁP

Ghép hai mô hình có sẵn, không huấn luyện thêm

SUBTASK 1 (1A, 1B)

"word": "kvinna", "sentence_id": "137d9286_62_69", "label": [0]

Câu + vị trí từ đích (cắt ±400 ký tự) → **XL-LEXEME:** vector của token đích → Agglomerative cosine, ngưỡng 0.08 → Gộp cụm có dưới 2 câu → Mã cụm mỗi câu → chấm 1a, 1b

THỬ TRƯỚC

bge-m3

Huấn luyện cho truy xuất văn bản qua vector. Vector của từng token bị kéo về nghĩa của cả câu.

CHỌN DÙNG

XL-LEXEME

XLM-R large tinh chỉnh cho Word-in-Context: so nghĩa của cùng một từ trong hai ngữ cảnh. Đúng tín hiệu cần để gom câu theo nghĩa.

Cùng quy trình phân cụm, chỉ đổi bộ mã hoá

Spearman 1b: **0.255** → **0.651**

3 · PHƯƠNG PHÁP

Dữ Liệu Thực Tế Trong Dataset – Khảo Sát Từ 'motiv'

CÂU 1 (NĂM 1882) – THẾ KỶ 19

ID: fcf69bc5_22_27 | Thời kỳ: 1880–1883

Văn bản gốc Thụy Điển:
*« A. Gödecke, Vexiö: **Motiv** från Dufnäs af A. Schultzberg; frii J. Gidlöf… »*

Dịch nghĩa tiếng Việt:
« …Đề tài / Họa phẩm từ vùng Dufnäs của danh họa A. Schultzberg… »

Nhãn thực tế (Ground Truth):
- **Subtask 1: Cụm Nghĩa [3] (Nghệ thuật)**
- **Subtask 2: Label = 1 (Khớp định nghĩa)**

CÂU 2 (NĂM 2023) – THẾ KỶ 21

ID: f51b433_64_69 | Thời kỳ: 2022–2023

Văn bản gốc Thụy Điển:
*« Hör Jessica… se fler av lastbilarna – med **motiv** från både hockeyvärlden till rockabilly – i klippet. »*

Dịch nghĩa tiếng Việt:
« …nhìn những chiếc xe tải được vẽ họa tiết / hình vẽ từ khúc côn cầu đến phong cách rockabilly… »

Nhãn thực tế (Ground Truth):
- **Subtask 1: Cụm Nghĩa [3] (Nghệ thuật)**
- **Subtask 2: Label = 1 (Khớp định nghĩa)**

CÂU 3 (NĂM 2011) – THẾ KỶ 21

ID: 28ac13b8_59_66 | Thời kỳ: 2010–2011

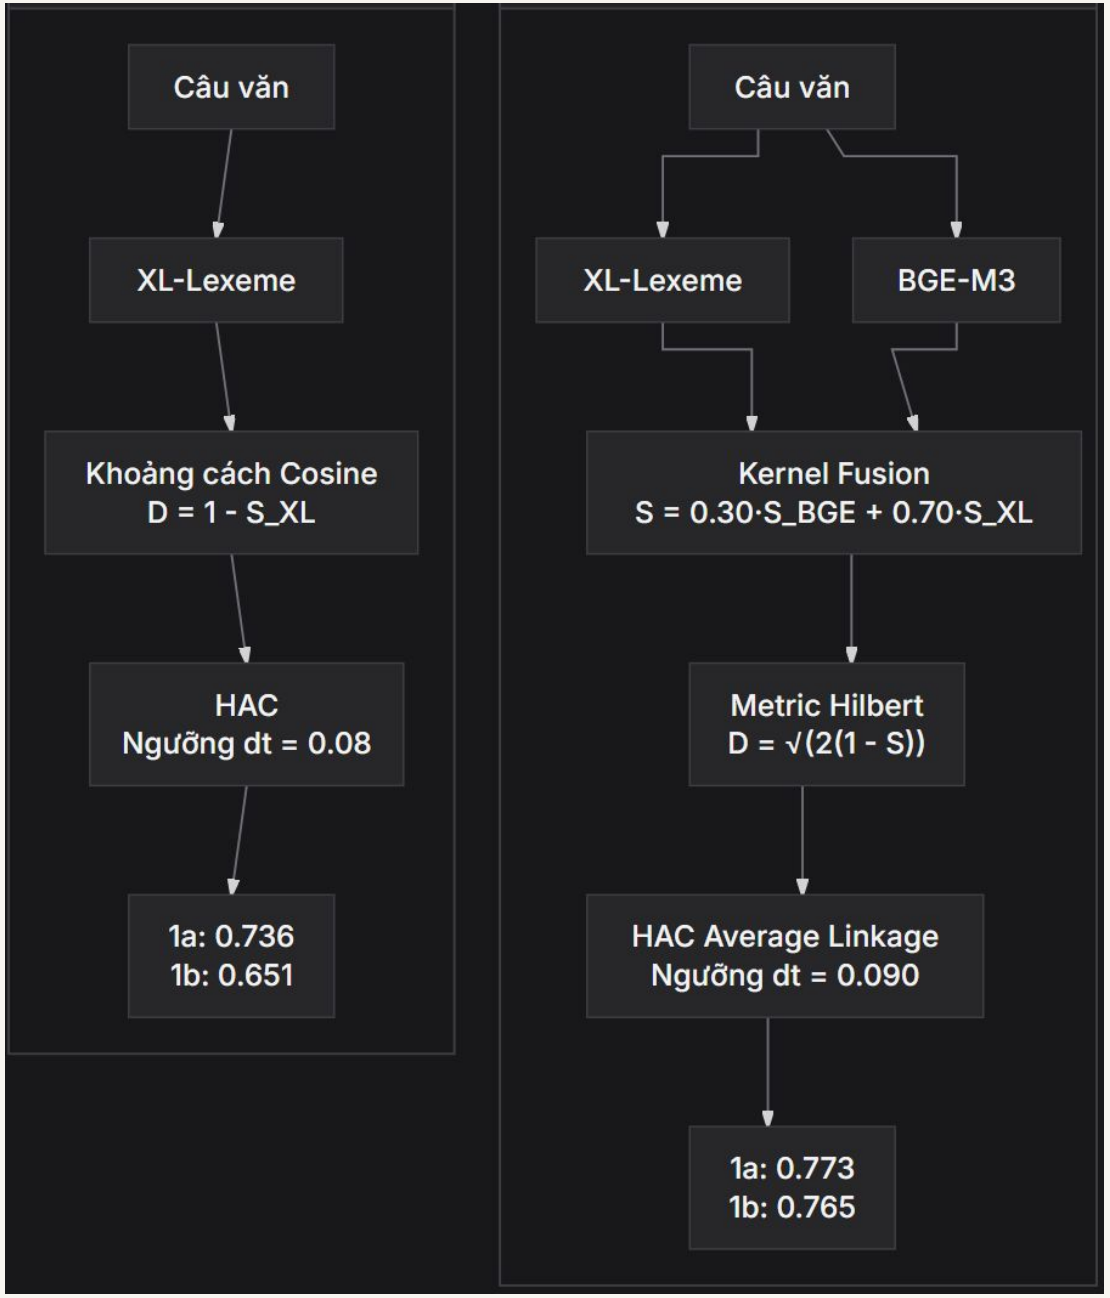
Văn bản gốc Thụy Điển:
*« Offret var en kriminell ligaledare och polisens tes är att **motivet** har en koppling till en schism… »*

Dịch nghĩa tiếng Việt:
« Nạn nhân là trùm băng đảng và giả thuyết của cảnh sát là động cơ liên quan tranh chấp taxi… »

Nhãn thực tế (Ground Truth):
- **Subtask 1: Cụm Nghĩa [4] (Động cơ tội phạm)**
- **Subtask 2: Label = 0 (Sai lệch định nghĩa)**

3 · PHƯƠNG PHÁP

Chọn XL-Lexeme



70% XL-Lexeme + 30% BGE-M3

3 · PHƯƠNG PHÁP

Cặp Câu So Sánh	Độ Tương Đồng Sfused	Khoảng Cách D	So Với dt = 0.090	Quyết Định HAC	Ground Truth	Kết Luận
Câu 1 (1882) & Câu 2 (2023)	0.9977	0.068	0.068 < 0.090 (Thấp hơn ngưỡng)	GOM CHUNG Cụm 3	Cụm [3] (Nghệ thuật)	✔
Câu 2 (2023) & Câu 3 (2011)	0.9895	0.145	0.145 > 0.090 (Vượt ngưỡng)	TÁCH RỜI Cụm 4	Cụm [4] (Động cơ tội phạm)	✔
Câu 1 (1882) & Câu 3 (2011)	0.9882	0.154	0.154 > 0.090 (Vượt ngưỡng)	TÁCH RỜI Cụm 4	Cụm [4] (Động cơ tội phạm)	✔

KẾT QUẢ ĐỐI SOÁT SUBTASK 2 CHO TỪ 'motiv'

- Định nghĩa mục tiêu: « Ämne för konstnärlig framställning inom bildkonst... »
- Câu 1 (1882): Dự đoán = 1 | Thực tế = 1 ✔ ĐÚNG
- Câu 2 (2023): Dự đoán = 1 | Thực tế = 1 ✔ ĐÚNG
- Câu 3 (2011): Dự đoán = 0 | Thực tế = 0 ✔ ĐÚNG

➤ F1-Score Subtask 2 đạt 0.9060!

KẾT LUẬN THỰC TIỄN CHO HỘI ĐỒNG SEMINAR

- Mô hình V4 không hoạt động ngẫu nhiên: Sự kết hợp 30/70 trên Hilbert giải quyết triệt để sự xung đột giữa ngữ cảnh vĩ mô và vi mô.
- Ngưỡng khoảng cách dt = 0.090 được chứng minh bằng thực nghiệm toán học rõ ràng, không phải là con số mò mẫm vô căn cứ.

Hệ thống	1a BCubed	1b Spearman	TB (1a+1b)/2
Gộp mỗi từ thành 1 cụm	0.756	không xác định	–
bge-m3, ngưỡng 0.30	0.766	0.255	0.511
XL-LEXEME, ngưỡng 0.10	0.736	0.590	0.663
XL-LEXEME, ngưỡng 0.08	0.736	0.651	0.693
XL-LEXEME, ngưỡng thích nghi theo từ	0.607	0.346	0.476
BGE 0.3 + XL 0.7, dt=0.09	**0.773**	**0.765**	**0.769**
gold standard	0.966	0.931	0.948

3 · PHƯƠNG PHÁP

Subtask 2: hỏi trực tiếp một LLM, không cần nhãn

SUBTASK 2

Câu (từ đích đánh dấu **...**) + định nghĩa nghĩa đích → **Qwen2.5-7B** (Ollama) trả lời một chữ số → Nhãn 0/1 mỗi câu → chấm F1

PROMPT (RÚT GỌN)

```
Target word (lemma): {word}
Year: {year}
Sentence (may contain OCR errors; target marked with
**):
{câu}
Sense definition: {định nghĩa}
Does the marked word express exactly this sense?
Answer with a single digit: 1 = yes, 0 = no.
```

Mô hình

Qwen2.5-7B-Instruct 4 bit, chạy qua Ollama

Biến thể: làm mượt theo cụm

Nếu tỉ lệ câu được trả lời 1 vượt ngưỡng thì gán 1 cho cả cụm

Chi tiết kỹ thuật

Không ngầm đổi lỗi thành nhãn 0, cache từng câu để chạy tiếp khi bị ngắt

4 · CÀI ĐẶT THỬ NGHIỆM

Thiết lập thử nghiệm

Môi trường

Python 3.9, Hugging Face, Ollama, không dùng GPU rời

Dữ liệu đánh giá

10 từ SV(Thụy Điển) có gold, phase dev trên Codabench chỉ chấm 2 từ (kvinna, motiv)

Tinh chỉnh

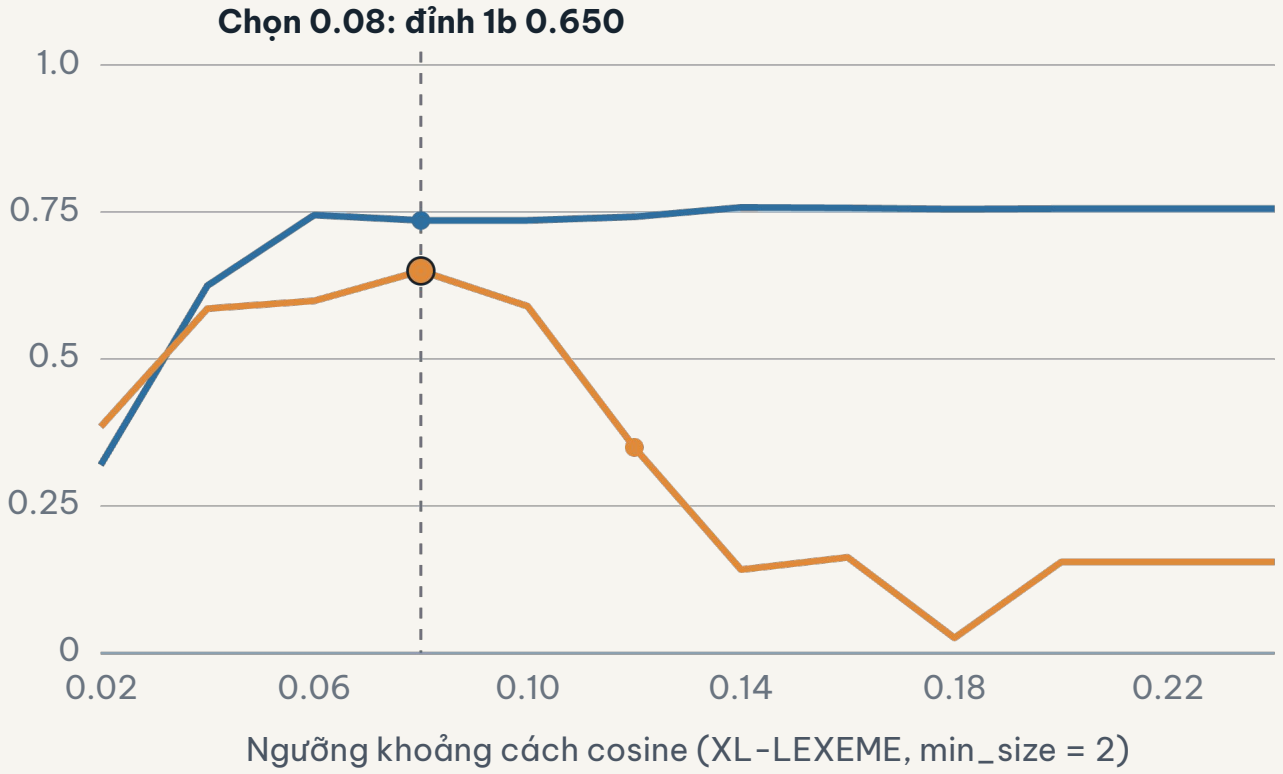
Lưới ngưỡng 0.02–0.30 × min_size ∈ {1, 2, 3, 5}; chọn theo subtask (1a + 1b) / 2

Chấm điểm

Chấm lại bằng bộ chấm chính thức của BTC.

4 · CÀI ĐẶT THỬ NGHIỆM

1b rất nhạy với ngưỡng phân cụm



1a BCubed

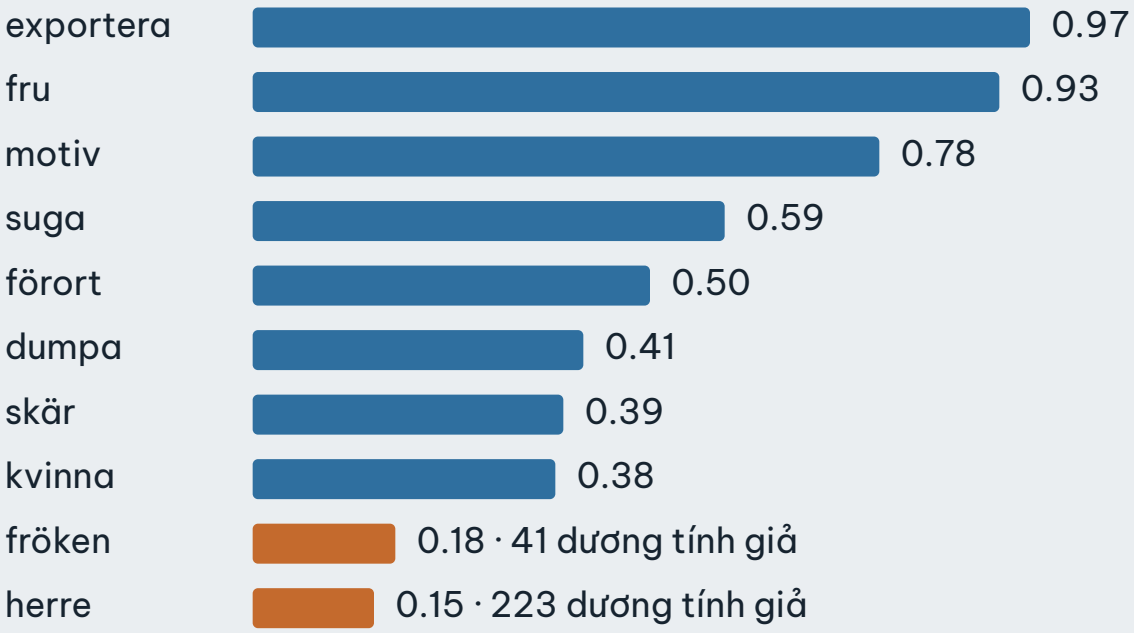
1b Spearman

Ngưỡng lệch 0.04 (từ 0.08 lên 0.12) làm Spearman giảm từ **0.65 xuống 0.35**, trong khi 1a gần như không đổi.

Ngưỡng được chọn trên chính 10 từ dev: đây là rủi ro lớn nhất khi chuyển sang 132 từ, 6 ngôn ngữ.

4 · CÀI ĐẶT THỬ NGHIỆM

Subtask 2: F1 0.529



Lỗi chủ đạo: trả lời 1 quá dễ

herre: nhận "Chúa", "quý ông" thành nghĩa "người thuộc giới quý tộc"

Làm mượt theo cụm: kém hơn

0.474 (ngưỡng 0.05), 0.305 (0.50). Cụm dự đoán quá thô

4 · CÀI ĐẶT THỬ NGHIỆM

Phần chạy đúng và phần chưa đúng

Chạy đúng

- Toàn bộ pipeline chạy hết; file nộp đúng định dạng Codabench
- 1b đạt 0.651 leaderboard, khá cao
- Subtask 2 đạt 0.529, vượt mốc đoán toàn 1 (0.472)
- Kết quả tái lập được bằng bộ chấm chính thức; độ lệch 1a trên leaderboard cũ do lỗi bộ chấm của BTC (đã sửa 05/10)

Chưa đúng

- 1a (0.736) vẫn thấp hơn mốc gộp 1 cụm (0.756)
- Subtask 2 trả lời 1 quá dễ ở nghĩa hiếm (herre, fröken)
- Làm mượt theo cụm và ngưỡng thích nghi đều làm điểm giảm
- Ngưỡng chỉ được chọn trên chính 10 từ dev, nên điểm dev lạc quan so với tập test

Subtask 2: so sánh các hướng trên

Hệ thống	Mô hình	F1 ST2	So với đoán toàn 1
Đoán toàn 1 (mốc)	—	0.472	—
LLM nhỏ, zero-shot (báo cáo cũ)	Qwen2.5-7B	0.529	+0.057
Không LLM: vector từ đích + NLI (Codabench)	XL-LEXEME / XLM-R + mDeBERTa	0.590	+0.118
LLM lớn, zero-shot	Gemma 4 31B	0.711	+0.239
LLM lớn + nghĩa đối chiếu	Gemma 4 31B	0.715	+0.243
LLM lớn + đối chiếu + few-shot (chọn)	Gemma 4 31B	0.728	+0.256

5 · HƯỚNG PHÁT TRIỂN

Hướng phát triển tiếp theo

Hướng	Nhằm khắc phục
Ngưỡng riêng từng từ theo silhouette, không cần gold	Ngưỡng chung không hợp mọi từ
Complete linkage, chọn lớp embedding	Cụm quá thô ở từ nhiều nghĩa (suga)
Subtask 2: chấm bằng xác suất token “1”, chọn ngưỡng	Dương tính giả ở nghĩa hiếm
Subtask 2 bằng XL-LEXEME: so câu với ví dụ nghĩa đích	Gọi LLM từng câu tốn thời gian
Thử trên dữ liệu tổng hợp tiếng Anh của BTC	Chưa kiểm tra trên 6 ngôn ngữ, 132 từ

KẾT LUẬN

Ba điều rút ra

Phân tích ngữ liệu trước

Mốc tầm thường "gộp 1 cụm" quyết định hàm mục tiêu đúng

Mô hình đúng bản chất

Đổi bge-m3 sang XL-LEXEME tăng 1b thêm 0.40; tinh chỉnh chỉ thêm vài phần trăm

Đúng trên gold chưa đủ

"ST2 là một cụm" đúng với gold nhưng chưa khai thác được bằng cụm dự đoán

Cảm ơn thầy cô và các bạn · Hỏi đáp

Appendix

Với phần tử i, gọi $C(i)$ là cụm hệ thống chứa i, $L(i)$ là cụm đúng (truth) chứa i:

$$\text{Precision}_i = \frac{|C(i) \cap L(i)|}{|C(i)|}, \qquad \text{Recall}_i = \frac{|C(i) \cap L(i)|}{|L(i)|}$$

$$P = \sum_{i=1}^{N} w_i \,\text{Precision}_i, \quad R = \sum_{i=1}^{N} w_i \,\text{Recall}_i, \quad F = \frac{2PR}{P+R}$$

Khi một phần tử thuộc nhiều cụm/nhãn (Task 3 cho phép `[1, 2]`), xét theo **cặp** (e, e'), với $C(e)$ là tập cụm hệ thống và $L(e)$ là tập nhãn đúng của e:

$$\text{MP}(e, e') = \frac{\min(|C(e) \cap C(e')|,\ |L(e) \cap L(e')|)}{|C(e) \cap C(e')|}, \qquad \text{MR}(e, e') = \frac{\text{n}}{}$$

- Precision của e = trung bình MP trên các e' **có chung ít nhất một cụm hệ thống** với e (kể cả chính e); P = trung bình trên mọi e.
- Recall của e = trung bình MR trên các e' **có chung ít nhất một nhãn đúng** với e; R = trung bình trên mọi e.
- Khi mỗi phần tử có đúng 1 nhãn ⇒ trùng khớp định nghĩa gốc.
- Amigó et al. đề xuất 4 ràng buộc hình thức cho độ đo phân cụm (độ thuần nhất, độ đầy đủ, "rag bag", kích thước so với số lượng) và cho thấy BCubed là độ đo duy nhất trong các họ họ khảo sát thoả cả bốn.

B Cubed

Appendix

(Cả file nộp của SemEval-2020 có dạng như sau:
fröken 0.39
motiv 0.12
kvinna 0.20
). Task 3 mở rộng ra tối đa 10 thời kỳ, theo dõi từng nghĩa, trên 6 ngôn ngữ, với 132 từ trong tập test.
đáp án dài hơn nhiều, từ trong câu nào ứng với nghĩa nào
fröken câu_001 [4]
fröken câu_002 [3]
fröken câu_003 [5]
... ← 174 dòng, mỗi câu một dòng
)

Submission

Appendix

ST2 relative ST1

Câu (rút gọn)	Gold ST1	Gold ST2
"Prins Carl Philip och **fröken** Sofia Hellqvist"	[4]	0
"Adam har berättat… att **fröken** har sagt"	[5]	0
"säljas i kommission hos **fröken** Andin" (hiệu buôn)	[3]	1
"barnmorskan **fröken** Foinander" (bà đỡ)	[3], 4	1
"husföreståndarinna **fröken** Signe Höglund" (quản lý trường nữ công)	[3], 5	1

Từ	dumpa	exportera	fru	fröken	förort	herre	kvinna	motiv	skär	suga
Mã nghĩa đích trong ST1	7	1	5	3	3	3	4	3	6	12

Quy luật: **ST2 = 1 khi và chỉ khi nhãn ST1 có chứa nghĩa [3]**. Câu mang nhiều nghĩa, ví dụ [3, 4], vẫn được tính là 1, miễn là có nghĩa [3]. Gold của Subtask 2 không phải được gán độc lập, mà suy ra từ gold của Subtask 1. Subtask 2 tương đương với hai bước: gom đúng các câu theo nghĩa, rồi chỉ ra cụm nào khớp với định nghĩa.

Appendix

(Bộ chấm chỉ so hai thời kỳ đứng liền nhau trong danh sách, nên cặp 1912–1915 → 2006–2007 cũng được tính là “liền nhau”. Thực tế hai thời kỳ này cách nhau gần một thế kỷ, đó là “cặp nối hai khối”. 5 từ có cả hai khối mới có cặp này: fru, fröken, herre, kvinna, motiv. Ở các cặp khác, từ chỉ có 4–8 năm để thay đổi. Ở cặp nối, những từ mất hẳn/đổi cách dùng.

Từ	JSD gold	JSD hệ thống	Nhận xét
fru	0.533 (hạng 1)	0.135 (hạng 26)	**bỏ lỡ** thay đổi lớn nhất
fröken	0.446	0.262	đoán thấp
herre	0.405	**0.877 (hạng 1)**	đoán **quá cao**
kvinna	0.392	0.130	bỏ lỡ
motiv	0.255	0.146	gần đúng thứ hạng

Gap period

Appendix

Nghĩa	P = 1912–1915	Q = 2006–2007
[3] phụ nữ làm nghề	0.174	0
[4] danh xưng "cô"	0.717	0.5
[5] cô giáo	0.109	0.5

KL là "số bit bị lãng phí nếu dùng Q để mô tả dữ liệu thực ra đến từ P". KL có hai nhược điểm khiến nó không dùng được:

- **Không đối xứng:** KL(P‖Q) ≠ KL(Q‖P). Khi đó "thay đổi từ 1912 sang 2006" lại khác với "thay đổi từ 2006 về 1912".
- **Bằng vô cùng** khi một nghĩa có ở P nhưng không có ở Q. Đây lại đúng là trường hợp ta quan tâm nhất: nghĩa [3] của fröken biến mất, Q([3]) = 0, nên KL(P‖Q) = ∞.

M không bao giờ bằng 0 ở nghĩa nào mà P hoặc Q có, nên JSD luôn hữu hạn và đối xứng.(sự tối ưu của phép cộng)

KL and JSD

$$\mathrm{KL}(P\|Q) = \sum_x P(x) \log_2 \frac{P(x)}{Q(x)}$$

$$M = \tfrac{1}{2}(P+Q), \qquad \mathrm{JSD} = \tfrac{1}{2}\,\mathrm{KL}(P\|M) + \tfrac{1}{2}\,\mathrm{KL}(Q\|M)$$

Appendix

Câu (rút gọn)	Chủ đề	Gold
A. “Metoden kallas ‘pumpa och **dumpa**’... köpa aktier, manipulera upp kursen”	chứng khoán	[5] vứt bỏ, đẩy đi
B. “bolaget **dumpar** priserna”	kinh tế, giá cả	[10] bán phá giá
C. “djurkadaver kan ha **dumpats** i havet”	môi trường	[5, 7]
D. “**dumpa** vatten på elden”	cứu hoả	[7] thả xuống

A và B cùng chủ đề kinh tế nhưng khác nghĩa.
A và C khác chủ đề nhưng cùng nghĩa [5].
Một bộ mã hoá lý tưởng phải đặt A gần C hơn A gần B. Độ tương đồng cosine thực tế trên embedding đã lưu:

Cặp	XL-LEXEME	bge-m3 (token đích)
A–B (cùng chủ đề, khác nghĩa)	0.942	0.692
A–C (khác chủ đề, cùng nghĩa)	0.904	0.605

Nghĩa của từ khác với chủ đề câu

4 · CÀI ĐẶT THỬ NGHIỆM

Subtask 1: kết quả trên 10 từ dev

Hệ thống	1a BCubed	1b Spearman	TB (1a+1b)/2
Gộp mỗi từ thành 1 cụm	0.756	không xác định	–
bge-m3, ngưỡng 0.30	0.766	0.255	0.511
XL-LEXEME, ngưỡng 0.10	0.736	0.590	0.663
XL-LEXEME, ngưỡng 0.08 (chọn)	0.736	0.651	0.693
XL-LEXEME, ngưỡng thích nghi theo từ	0.607	0.346	0.476
gold standard	0.966	0.931	0.948